



安徽农业大学
Anhui Agricultural University

专业硕士学位论文

基于PIDNN的温室温度 控制与研究

Greenhouse Temperature Based on PIDNN
Control and Research

姓 名 _____ 何雨宏

导 师 _____ 梁惠

校外导师 _____ 李军

_____ 北方雷科（安徽）科技有限公司

学位类别 _____ 农业硕士

领域名称 _____ 农业工程与信息技术

研究方向 _____ 农业信息化

学 院 _____ 信息与计算机学院

2022 年 06 月

中图分类号: TP399

单位代码: 10364

UDC: 63

密 级: 公开

安徽农业大学

专业硕士学位论文

基于 PIDNN 的温室温度 控制与研究

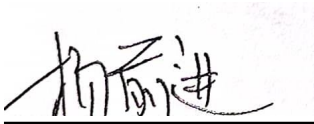
Greenhouse Temperature Based on PIDNN Control and Research

姓 名: 何雨宏 学 号: 20723012

导 师: 梁惠 校 外 导 师: 李军

专业学位类别: 农业硕士 北方雷科(安徽)科技有限公司

领 域 名 称: 农业工程与信息技术 研 究 方 向: 农业信息化

学 院: 信息与计算机学院 答辩委员会主席: 

论文评阅人: _____

2022 年 06 月

A Dissertation Submitted to Anhui Agricultural University
in Partial Fulfillment of the Requirements for
the Professional Master of Agriculture

Greenhouse Temperature Based on PIDNN Control and Research

by

Yuhong He

Supervised by

Lecturer Hui Liang

June, 2022

College of Information and Computer Science
Anhui Agricultural University
Hefei, Anhui, P.R.China

独 创 性 声 明

本人声明：所呈交的论文是我个人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得安徽农业大学或其它教育机构的学位或证书而使用过的材料。对本文成果做出贡献的个人和集体，本人已在论文中作了明确的说明，并表示谢意。

研究生签名： 何雨婷

时间： 2022 年 06 月 1 日

关于论文使用授权的声明

本人完全了解安徽农业大学有关保留、使用学位论文的规定，即：学校有权保留送交论文的复印件和电子版，允许论文被查阅和借阅，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。同意安徽农业大学可以用不同方式在不同媒体上发表、传播学位论文的全部或部分内容。

☐ 本论文延迟____年后公开，到期后适用本授权。

（限制级及涉密学位论文请在上方“☐”内划“√”，并填写延迟公开时限，限制级论文延迟公开时限最多不超过3年。不勾选此项，默认为立即公开）

研究生签名： 何雨婷

时间： 2022 年 06 月 1 日

第一导师签名： 梁惠

时间： 2022 年 06 月 1 日

致 谢

行文至此，落笔为终。毕业如一场声势浩大的剧目，终于落下帷幕。此间的喜怒哀乐、辛酸苦辣，个中滋味，实是冷暖自知。两载春秋，近处感受，时常觉着冗长而乏味，而在远处回望，又惊觉时光弹指一挥，飞逝如电。在此，向这条路途中我的家人、老师、朋友，致以最诚挚的谢意。

首先感谢导师梁惠老师以及校外导师李军老师，感谢你们对我学业的支持，尊重并接纳我的价值观中对于科研与就业的分歧，在某种意义上给予了自由抉择的权利，感谢您对于我毕业论文的指导，学术探究于我如巍巍高峰，是你们为我指引了一条明路。

其次，感谢中西部大楼 777 实验室的全体研究生与本科生，两年的绝大部分时间中，我们都在一起并肩作战，一起谈天说地，一起嬉笑怒骂。放荡不羁不拘一格的啸哥，幽默风趣出口即是段子的阳哥，对科研满怀热忱之心的秀峰，坦荡潇洒、率性又随和的凯哥，成熟稳重的潇哥，深耕技术对事物常有独特思考的克清，风度翩翩又谦逊礼貌的巴基斯坦“老铁”Roy 同学，高冷认真又时常会流露出几分俏皮的叶晨，笑容烂漫、一直在追逐自己学术梦的小童琳，他们各自都有着不一样的人格魅力、各自都有着属于自己的风采光芒。

然后，感谢我的室友们还有飞飞、涛哥、昆明，我们在好多个白昼与夜晚欢唱与呐喊，这将成为我脑海里难以磨灭的记忆。还有佩云学妹，感谢你在我迷茫时给我的鼓励与温暖，让我在挫折与失望中重拾希望与信心，让我在无边困境中学会勇敢！

最要感谢我的父母给予我亲情的陪伴，我贫瘠的语言描绘不出你们万分之一的好的，也表述不了我内心汹涌情感的分毫。没有你们辛辛苦苦 24 年的付出，就没有现在撰写毕业论文的我；没有你们的陪伴，就没有现在阳光正直的我。你们是我内心深处最温暖的港湾，也是漫漫长夜中照亮我前行的灯塔。

最后，感谢各位评审的专家能够在百忙之中抽出时间参与本论文的各项工作，感谢你们对本文提出的宝贵建议，使得本文能够更加完善！

作者：何雨宏
2022 年 3 月 11 日

摘要

温度是维持农作物生长极为重要的一个参数,温室大棚是现代农业中能够为农作物在不同季节、不同气候提供适宜生长温度环境的关键设施。使用传统 PID 控制的方法调控温室大棚温度,这类方法自动化、智能化水平较低,过于依赖人工经验且效率低下,难以实现对温室大棚这种非线性、大滞后、强耦合复杂对象高效而精确的控制。因此,本文提出了一种将遗传算法与改进的 PID 神经网络结合的控制算法(GA-MPIDNN),实现了对塑料温室大棚温度高效率、高精度、高稳定性的调控。本文主要的研究工作总结如下:

(1) 根据自然界中的热平衡定律推导出温室大棚动态数学模型传递函数的形式,再通过对塑料温室大棚注入阶跃信号,根据阶跃响应曲线使用两点拟合算法进行数学运算求得模型各参数的实际值,最终获得此环境下温室大棚具体的动态数学模型。

(2) 针对大惯性、大时滞的温室大棚环境,本研究利用求得的大棚温控系统数学模型,尝试将具有自学习特性的神经网络引入 PID 控制器(PIDNN),结合遗传算法初始化最优权值,以添加动量项的方式改进 BP 网络的反向传播运算,构成具有良好收敛性、自适应特性的 GA-MPIDNN 控制器,再在温室大棚温度的仿真环境进行调控。结果表明:在 ZN 法与遗传算法的基础上,GA-MPIDNN 算法有效降低了调控过程的超调量、缩短了调控时间,同时提高了系统稳态性,在诸多方面提高了控制系统的动态性能。

(3) 将仿真实验中呈现出最优调控性能的 GA-MPIDNN 算法引入现实环境,搭建一个基于 GA-MPIDNN 的小型温室大棚智能化温控系统。利用 Python 与单片机的串口通信搭建系统的上位机,结合传感器与单片机间的温度信息传递、单片机与执行机构间的控制信号传递搭建系统的下位机。设定调控的目标温度,进行现实环境下此系统的温度调控并得到测试结果,该测试结果表明此系统成功实现了智能化温度控制且达到了较为理想的调控效果。

关键词: 温室大棚; 温度控制; PID 控制; 遗传算法; 神经网络

ABSTRACT

Temperature is an extremely important parameter to maintain crop growth. Greenhouse is a key facility in modern agriculture that can provide suitable growth temperature environment for crops in different seasons and different climates. The traditional PID control method is used to control the temperature of the greenhouse. This kind of method has a low level of automation and intelligence. It relies too much on manual experience and is inefficient. Therefore, this paper proposes a control algorithm (GA-MPIDNN) that combines genetic algorithm and improved PID neural network to achieve high-efficiency, high-precision, and high-stability control of plastic greenhouse temperature. The main research work of this paper is summarized as follows:

(1) The form of the transfer function of the dynamic mathematical model of the greenhouse is deduced according to the law of heat balance in nature, and then by injecting a step signal into the plastic greenhouse, and using a two-point fitting algorithm to perform mathematical operations according to the step response curve, the model is obtained. The actual values of the parameters are finally obtained to obtain the specific dynamic mathematical model of the greenhouse under this environment.

(2) For the greenhouse environment with large inertia and large time delay, this study uses the obtained mathematical model of the greenhouse temperature control system to try to introduce a neural network with self-learning characteristics into the PID controller (PIDNN), and combine the genetic algorithm to initialize the most optimal weight value is added to improve the back-propagation operation of the BP network by adding a momentum term to form a GA-MPIDNN controller with good convergence and self-adaptive characteristics, which is then regulated in the simulation environment of greenhouse temperature. The results show that: based on the ZN method and the genetic algorithm, the GA-MPIDNN algorithm effectively reduces the overshoot of the control process, shortens the control time, and at the same time improves the stability of the system, and improves the dynamic performance of the control system in many aspects.

(3) The GA-MPIDNN algorithm, which showed the optimal control performance in the simulation experiment, was introduced into the real environment, and an intelligent temperature control system for small greenhouses based on GA-MPIDNN was built. The upper computer of the system is built by using the serial communication between Python and the single-chip microcomputer, and the lower computer of the system is built by

combining the temperature information transmission between the sensor and the single-chip microcomputer, and the control signal transmission between the single-chip microcomputer and the actuator. The target temperature for regulation is set, the temperature regulation of the system is carried out in the real environment and the test results are obtained. The test results show that the system has successfully achieved intelligent temperature control and achieved a relatively ideal regulation effect.

KEYWORDS: Greenhouse; Temperature control; PID control; Genetic algorithm; Neural network

目 录

1 绪论	1
1.1 研究背景与意义	1
1.1.1 研究背景	1
1.1.2 研究意义	1
1.2 研究现状	2
1.3 本文研究内容	3
1.4 论文章节安排	4
1.5 小结	5
2 基于 PID 参数整定的温室大棚温度控制	6
2.1 温室大棚温控系统模型的建立	6
2.2 常规 PID 控制	8
2.2.1 PID 控制基本原理	8
2.2.2 PID 参数整定的研究	11
2.2.3 PID 控制的评价指标	11
2.3 ZN 法整定 PID 参数调控温室大棚温度	12
2.3.1 ZN 临界比例度法方法简介	12
2.3.2 仿真研究	13
2.3.3 ZN 临界比例度法的缺点	16
2.4 遗传算法	16
2.4.1 遗传算法的理论提出	16
2.4.2 遗传算法的概念	17
2.4.3 遗传算法的关键技术	17
2.4.4 遗传算法的基本流程	20
2.5 基于 GA-PID 调控温室大棚温度	21
2.6 实验结果对比分析	24
2.7 小结	24
3 基于 GA-MPIDNN 算法的温室大棚温度控制	25
3.1 神经网络	25
3.1.1 神经网络的基本理论	25
3.1.2 神经网络的应用领域	26
3.2 基于遗传算法与 BP 神经网络结合的 PID 控制	27
3.2.1 PIDNN 控制器及神经网络结构	27
3.2.2 遗传算法初始化权值	29
3.2.3 反向传播自适应调整权值	29
3.3 改进 BP 算法优化的 PIDNN	32
3.4 基于 GA-MPIDNN 的温室大棚温度仿真控制	34
3.4.1 控制器结构与调控流程	34
3.4.2 仿真结果	35
3.5 实验结果对比分析	37

3.6 小结	37
4 小型温室大棚温度控制系统的构建	38
4.1 系统整体设计	38
4.2 系统上位机	39
4.3 系统下位机	41
4.4 温度调控的实际测试	44
4.5 小结	46
5 总结与展望	47
5.1 全文总结	47
5.2 展望	48
参考文献	49
作者简介	53

插图清单

图 2-1 温度响应曲线图	7
图 2-2 PID 控制器原理图	9
图 2-3 系统单位阶跃响应及其 PID 评价指标图	12
图 2-4 数字模拟器原理图	14
图 2-5 系统闭环响应曲线	15
图 2-6 遗传算法基本流程图	20
图 2-7 性能指标 J 的优化过程曲线图	22
图 2-8 系统闭环仿真调控过程曲线图	23
图 3-1 基于 BP 网络的 PID 控制系统原理图	27
图 3-2 PID 神经网络结构图	28
图 3-3 GA-PIDNN 与 GA-MPIDNN 温控闭环响应曲线	33
图 3-5 GA-MPIDNN 控制器结构图	34
图 3-6 GA 优化权值阶段适应度分数的迭代	35
图 3-7 系统闭环响应曲线	36
图 4-1 系统结构图	38
图 4-2 系统登录界面	39
图 4-3 系统控制主界面	40
图 4-4 USB-CH340 串口通讯线	40
图 4-5 串口助手图	41
图 4-6 STM32F103C8T6 核心板	42
图 4-7 传感器实物图	43
图 4-8 PTC 直流风扇实物图	44
图 4-9 下位机的连接	44
图 4-11 控制系统实际温度变化曲线图	45
图 4-12 小型温室大棚温度控制系统	46

表格清单

表 2-1 ZN 临界比例度法对不同类型控制的参数整定表	14
表 2-2 ZN 法控制仿真结果表	15
表 2-3 (GA)遗传算法仿真调控结果表	23
表 2-4 ZN 法与遗传算法仿真效果对比表	24
表 3-1 跟踪性能对照表	33
表 3-2 GA-MPIDNN 仿真调控结果表	36
表 3-3 此环境下不同方法仿真效果比较表	37
表 4-1 STM32F103C8T6 核心板主要参数表	42
表 4-2 传感器性能参数表	43
表 4-3 系统实际环境调控效果表	45

1 绪论

1.1 研究背景与意义

1.1.1 研究背景

“温室大棚”内部具有能够加热、通风、透光的设施，在现代农家生活中，当外部温度过高或过低时，养殖者可通过温室大棚为植物提供一个较为适宜的生长环境，让农民可以在恶劣的环境中培育出反季节的植物，使农作物的产量、培育存活率等能在一定程度上得到提高，从而大大降低种植成本^[1]。现如今，位于全国各地的农家种植都少不了对于温室大棚的应用，温室大棚的普及不仅大大满足了广大城乡居民对于农家蔬菜的需求，充裕了他们的菜篮子，而且也给千家万户的农民带来了巨大的经济效益，开拓了一条绿色健康的获取财富的广阔道路，真正意义上实现了“勤劳致富”。

伴随着温室大棚农作物栽培技术的不断交流推广，农作物栽培的规模也在不断扩大。而温度又是温室大棚农作物种植过程中的一个极其重要的物理参数^[2]，不同种类的农作物生长所需的适宜温度的范围大多不同，一些喜热、适合在高温环境下生存的植物（如西瓜、丝瓜等瓜类蔬菜），它们在一个相当高的温度下也能正常生长，而这类蔬菜在较低的温度环境下便极易失去活性，极寒天气会严重危害它们的生长；另外一类是一些喜低温、适合在较为清凉的天气下生长的植物（如韭菜、芹菜等蔬菜），一般适合在白昼 15~22 摄氏度、晚间 10~15 摄氏度的环境下生长，这类植物能够忍受较短时间的零下低温，然而当外界温度较高时，它们便很有可能发生变质进而失去活性。还有一些反季节的蔬菜和水果对于外界的环境温度也有很高的要求，一旦遇到较为极端的天气，就有很大的概率产生虫害并大量减产。由此可见，对于温室大棚温度进行高效而精确的控制是农业发展过程中的重中之重。

目前我国温室大棚的管理设施仍然是一些简易设备，智能化水平较低，对人力物力的要求较高，难以对温度进行实时高精度的调控，主要管理方式过于依赖人工经验，这也导致对温室大棚温度的调控存在着诸多问题，比如效率低^[3]、所需成本较高、调控时间较长等等。基于这些问题，我们需要对农业温室大棚温度的智能化调控策略进行深度探究。

1.1.2 研究意义

温室大棚是一个经人工搭建的可为农作物的生长提供一个适宜培育环境的复杂生态系统。它的内部环境相对封闭，搭建温室大棚应尽可能将外部恶劣气候的干扰降低，以此保障农作物的正常生长^[4]。大田环境里的作物，当外界环境温度较低极其寒冷或者温度较高气候炎热时，产量都会大大降低，生长状况也会颇受影响。一些反季

节作物通常对于外界温度要求较高，普通的大田环境无法满足这类植物的生长^[5]。所以，对于温室大棚温度的调控此时就显得尤为重要，然而当下由于温室大棚智能化程度较低，管理过于依靠人力以及人工管理经验，不仅需要耗费较高的成本，而且难以对其进行精确调控。针对这些状况，本文对温室大棚温度控制的方法展开研究与优化，希望能够将不断发展的现代计算机技术用于农业温室大棚，改变温室大棚温度由于大惯性、大滞后等特点难以取得较好控制效果的问题，如采用具有在线自适应调整能力的神经网络，减小外部环境对温室大棚温度的剧烈干扰，降低温度控制过程的超调量、稳态误差以及能量消耗，减少此过程所需的调节时间，达到对于农业温室大棚高精度、高品质的控制效果，以此减少人力物力的巨大成本，提高广大劳动人民耕作所产生的经济效益^[6]。

1.2 研究现状

随着温室大棚规模的不断扩大，对于温室大棚温度的调控方式也在不断精进、不断成熟^[7]。为了提高作物产量，减低成本能耗，国外早期就已经有科研人士开始针对温室大棚环境的调控方式进行深度探究^[8, 9]。对于不同类别的农作物与温室大棚，需要根据其各自的特点使用不同的方法进行调控。近年来，有大量先进的温室大棚环境控制技术和方法策略被提出，比如预测控制^[10-12]、自适应控制^[13, 14]、非线性反馈控制^[10, 15]、模糊控制^[16]、鲁棒控制^[17, 18]、最优控制^[19]等等。我国早期对温室大棚控温的这方面的研究大多数是采用传统的比例，积分和微分（PID）控制器实现，此控制器结构简单，容易实现，同时还有着优越的性能。

PID 调控是工业界常用的一种调控手段，应用广泛，大约 95% 的过程控制^[20]、电机驱动乃至仪表行业的调节控制器都涵盖着 PID 控制器的结构。尽管应用广泛，但是 PID 控制在很大程度上依赖于工作人士过往的实际手工操作经验，实际操作方式通常是将温室大棚环境测量的实际温度，与给定的设定温度进行比较再进一步手动调控。倘若调谐不良，其有效性常常会受限，所以对 PID 控制器参数进行有效的调整依然是各界学者积极研究的主题。随着对此领域的不断探索，多种 PID 参数调整方法应运而生，如 Ziegler-Nichols（ZN）与 Cohen-Coon（C-C）方法。然而这类传统方法大多基于线性模型，调整方式主要围绕操作点，对找到最优增益参数集没有一个有效的分析方式，同时又缺乏针对复杂问题的经验数据，所以很难在非线性、强干扰的控制系统上取得良好的性能，难以满足高效迅速地调控温室大棚环境这种复杂系统的需求。

2007 年，WD Chang 提出一种使用多变量 PID 控制器调谐的多交叉遗传方法^[21]，将遗传算法（GA）调节 PID 参数这种极佳的调谐方式成功应用于大量的温室大棚植物^[22]。遗传算法具有强大的全局优化能力，在很多不同的控制问题上，它都能基于性能标准搜索到最优 PID 增益参数。然而此过程中，优化时的计算成本和对计算时间的

严重依赖性使之存在限制,也就导致 GA-PID 控制器难以在进行在线实时控制时取得很好的效果。2014 年^[23], 研究人员基于神经网络的自适应特性、自学习能力, 鲁棒性强、容错性强的特点和它对非线性函数强大的逼近能力开始将神经网络应用在非线性的自适应控制领域^[24, 25], 通过将传统的 PID 控制器与神经网络两相结合对温室大棚进行智能化温控, 使用 MATLAB 实施仿真, 实验结果证明使用神经网络优化 PID 参数相比之传统的 PID 控温在一定程度上效果更佳。现阶段, 研究人员还尝试将群智能算法用于调整 PID 控制器的参数, 在 2019 年, 李二^[26]在智能调整 PID 参数的过程中添加了种群自适应变异策略, 这种方法基于非线性权重的 PSO 寻优, 可以改变传统 PID 控制过程过早收敛的缺陷, 从而更合理地优化调整 PID 参数。

综上所述, 国内外学者对于智能调节 PID 控制器参数以实现温室大棚温度的精确调控做了大量的研究与探索, 目的是利用这类智能控制算法的优秀特性, 结合人力物力成本较高的传统 PID 控制器, 对有着非线性、大时滞、强干扰等复杂特性的温室大棚进行高效迅速的智能化温度调节, 从而提高农家收成, 创造更大的经济效益。

1.3 本文研究内容

本文基于我国农业温室大棚对于环境温度的调控和对温室大棚环境的管理方式中存在的一些不足与缺陷, 以及温室大棚温度对于农作物生长的重要性与它作为温室大棚环境中一个极为重要的物理参数却具有大时滞、大惯性这类不易调控的特性等因素, 结合上文中所陈述的各类智能调控算法的各自优良特性, 提出利用改进的 BP 神经网络与遗传算法相结合来优化 PID 控制这种方式, 以达到精准高效地调控温室大棚温度的目的, 从而大大提升温室大棚作物的生产效率, 进一步实现温室大棚的自动化调控、智能化管理。本文的具体研究内容主要包括以下几个方面:

(1) 塑料温室大棚温度控制系统的数学模型建立

温室大棚是一个易受多种环境因素影响的复杂系统, 具有时变性、非线性、大滞后、大惯性的特点。因此, 为达到对温室大棚温度智能化调控的目的, 我们以一个塑料温室大棚为被控对象, 注入阶跃信号至调控对象以测得该对象的阶跃响应曲线, 再采用曲线的两点拟合算法来确定此调控过程的近似传递函数, 完成系统动态模型的建模。

(2) 温室大棚温度控制方法的制定以及其仿真控制

针对不同智能控制算法的各自特性, 本文提出使用几种典型的控制策略用于农业温室大棚温度调控的仿真实验, 如具有很强的鲁棒性、可靠性, 结构简单且常被用于工业控制过程的 PID 控制; 用 ZN 法整定 PID 参数实现温度调控; 基于遗传算法优化 PID 参数; 基于遗传算法与改进 BP 神经网络的结合优化 PID 控制器参数。将几种方法都用于温室大棚以实现温度的高效调控。

(3)系统仿真实验结果的对比分析

分析使用上述方法进行温室大棚温度调控的过程,将仿真的实验结果进行可视化展示,再对几种方法各自的实验结果进行对比,选取控制效果最优的方法实际用于塑料温室大棚,以改善当下大棚温度控制过程调节时间长、响应速度慢、超调量较大、误差也较大等问题,有效提高其稳定性、鲁棒性。

(4)大棚温度控制系统上下位机的设计搭建与功能实现

搭建一个装有花卉绿植的塑料温室大棚,选择适合调控此大棚的温控硬件设备(如 STM32F103C8T6 单片机、加热风机等),利用 python 编写大棚的后台管理层(将温室大棚温度的实际智能控制算法编写于其中),后台接收到外部环境实际的温度数据,将此数据与预先设定设定的目标温度数据进行差值运算,再执行后台中的智能控制策略,产生实际的控制信号数据,利用串口通信的方式将控制信号的数据传输到温控设备,从而实现实际温室大棚环境中的温度调控。

1.4 论文章节安排

本研究分别采用传统方式(ZN 法)调节 PID 控制器参数、遗传算法优化 PID 控制器参数、基于遗传算法与改进的 BP 神经网络结合调整 PID 控制器参数几种不同的算法实现对农业温室大棚温度的智能化控制。本文结构主要安排如下:

第一章绪论。这一章节对温室大棚温度控制的研究背景、研究目的与意义以及国内外对农业温室大棚温度控制的研究现状做了较为详细的论述。然后总结了本文的研究内容,阐述了本文的各章节分布结构。

第二章基于 PID 参数整定的温室大棚温度控制。此章节首先根据自然界中的热平衡定理以及大棚系统阶跃响应曲线的两点拟合算法得出大棚温控系统的动态数学模型,紧接着介绍了 PID 控制器各参数的含义与其在实际的控制阶段给调控过程带来的影响以及 PID 的控制原理。其次介绍了一种传统的 PID 参数整定方法(ZN 法)并将此方法用于温度调控过程,确定了此过程的评价指标。然后又介绍了遗传算法的基本原理和相关概念,并利用遗传算法整定 PID 参数对大棚温度过程进行仿真调控。将此两种方法的仿真实验结果(即温度的实际调控效果)进行对比分析,得出遗传算法优化 PID 参数相比 ZN 法对温室大棚温度的调控效果更佳的结论。

第三章基于 GA-MPIDNN 的大棚温度控制。这个章节首先介绍了 PID 神经网络的理论知识以及各层次结构;其次介绍了遗传算法确定神经网络的初始权值与反向传播自适应调整权值的过程;随后再通过添加动量项的形式改进 BP 算法;使用遗传算法与改进的 PID 神经网络结合的方式对大棚温度进行仿真调控。最后将此方法调控的性能指标值与 ZN 法整定 PID 参数、GA 优化 PID 参数的方法进行对比分析,得出 GA-MPIDNN 更适用于温室大棚温度智能化控制的结论。

第四章塑料温室大棚温控系统的环境搭建以及实际调控。这一章节介绍了温室大棚温度控制系统的温度调节的硬件环境与执行上述最优智能调控 PID 参数策略的软件环境，在它们之间以串口通信的方式传递控制信号的数据，最终达到稳定精确地智能化调控大棚温度的目的。

第五章总结与展望。将本课题所研究领域的相关背景、研究意义与本文所做的研究工作以及在此过程中所得的研究成果进行了一个全面的总结，并对未来在此领域上的进一步优化与改进、研究与探索提出了展望。

1.5 小结

本章从温室大棚温度控制的背景出发，概述了本课题研究的意义、现状，简要分析了能够进行温室大棚温度智能化调控几种控制算法，接着阐述了本文的主要研究内容，最后介绍了论文的各章节安排、梳理了全文的结构，为后文奠定了坚实的基础。

2 基于 PID 参数整定的温室大棚温度控制

2.1 温室大棚温控系统模型的建立

在工农业控制领域中,控制系统的建模对于系统机理特性的分析与系统调控方案的设计至关重要。通常把一个控制对象在多个控制量的输入作用下产生的相应输出量的变化此过程以函数表达公式的形式表现出来,此公式即可称之为该对象的数学模型。温室大棚是一个易受多种环境因素影响的复杂系统,具有大滞后、大惯性、时变性的特点。因此,为达到对温室大棚温度智能化调控的目的,本文以一个小型温室大棚为被控对象并对其建模,从而得到它的传递函数。

本系统的建模机理为自然环境中的热平衡定律,根据能量守恒可知,单位时间流入温室大棚的热量与从温室大棚流出热量两者之间的差值与温室大棚内部所存储热量的改变值相等。

假设 T_i 代表温室大棚内部的被控温度; T 表示温室大棚外界空气温度;温室大棚内部与外部之间的传热系数用 H 表示;用温室大棚 Q_1 表示温室大棚向外界传递的热量,于是有公式 (2-1)。

$$Q_1 = H(T_i - T) \quad (2-1)$$

令 Q 为温室大棚棚内加热器电阻丝发出的总热量,温室大棚内部从外界吸收的热量为 Q_0 , 所以温度与总热量间的关系可以近似为公式 (2-2)。

$$Q_0 = Q - Q_1 = GC_\rho \frac{dT}{dt} = C \frac{dT}{dt} \quad (2-2)$$

此式中用 G 表示被加热空气的重量,用 C_ρ 表示空气的比热容,以 C 代指总的增益系数,于是可得到公式 (2-3)。

$$\begin{cases} Q - Q_1 = C \frac{dT_i}{dt} \\ Q_1 = H(T_i - T) \end{cases} \quad (2-3)$$

由于温室大棚初始状态为稳态,温度变化量极其微小且变化速度相当缓慢, $\frac{dT}{dt}$ 值较小趋近于 0, 即 $\frac{dT}{dt} = 0$ 。将温室大棚内部、外部温度关系使用温度增量的形式表示, 即 $T_\Delta = T_i - T_0$, 再对公式 (2-3) 在零初始状态下进行拉氏变换, 可得公式 (2-4)。

$$\begin{cases} Q(s) - Q_1(s) = CsT_\Delta(s) \\ Q_1(s) = HT_\Delta(s) \end{cases} \quad (2-4)$$

再经过变换运算, 令 $K = \frac{1}{H}$, $T = \frac{C}{H}$, 可获得温室大棚内部总输入热量与温度变化量之间的传递函数, 用公式 (2-5) 表示。

$$G(s) = \frac{T(s)}{Q(s)} = \frac{1}{Cs + H} = \frac{\frac{1}{H}}{\frac{C}{H}s + 1} = \frac{K}{Ts + 1} \quad (2-5)$$

此公式中， K 代表本实验中温室大棚的比例系数， T 表示时间常数。

自然界中的热传导现象一般指的是高温物体自发的将热量传递给低温物体的过程，而此过程中通常都会存在输入与响应之间时间的滞后，所以可给公式（2-6）再加上一个时滞环节并由此得出系统的传递函数^[27]表达式为^[28]：

$$G(s) = \frac{\Delta T}{\Delta Q} = \frac{Ke^{-\tau s}}{Ts + 1} \quad (2-6)$$

公式（2-6）中： K 表示系统的增益系数（本模型中可理解为内部加热器输出电压与温室大棚温度控制器的输出比例的关系）， T 表示时间常数， τ 表示系统的死区时间，即滞后时间。

当前工业控制领域中针对调控过程确定该过程的近似传递函数使用较为频繁的方法是注入阶跃信号至调控对象以测得该对象的阶跃响应曲线进而利用该曲线来辨识此调控过程的近似传递函数，本节研究中具体采用的是由 Marlin^[29]提出的此曲线的两点拟合算法^[30, 31]。

搭建一个小型温室大棚实验箱，给定注入的阶跃信号 12V 电压，将系统的响应数据（温室大棚的温度值）记录并通过 Excel 绘出此温箱的温度变化曲线，如图 2-1 所示。




图 2-1 温度响应曲线图

Fig 2-1 Temperature response curve

由阶跃曲线的两点拟合算法可知：

$$\begin{cases} K = \frac{\Delta C}{\Delta M} \\ T = 1.5(t_{0.632} - t_{0.28}) \\ \tau = t_{0.632} - T \end{cases} \quad (2-7)$$

此公式中， ΔM 表示系统的阶跃输入（本系统中为电压信号）， ΔC 代表系统相应输出响应（本系统初始温度与到达稳态后温度的变化量）， $t_{0.28}$ 表示系统的输出响应曲线到达 0.28 倍温升所对应的时间， $t_{0.632}$ 表示系统的输出响应曲线到达 0.632 倍温升所对应的时间。于是计算得出：

$$K=2.5, \quad T=277, \quad \tau=32。$$

即本研究中的温室大棚温度模型为 $G(s) = \frac{2.5e^{-32s}}{277s+1}$ 。

2.2 常规 PID 控制

PID 控制因其控制方式简单，且调控过程中能让被控对象表现出不错的鲁棒性与精确性，因此被应用在多个控制领域，是当下工业界应用较为广泛的一种控制方法。随着 PID 控制器理念的愈加纯熟与计算机技术的不断发展，PID 控制器的实现方式也越来越多样，现代化生产中，人们可以利用计算机中种类繁多且功能强大的软硬件资源，实现智能化、自动化程度较高的数字 PID 控制，从而让 PID 控制器在使用方式更为灵活的同时控制效果也越来越好，这种调控方式得到工农业研究人员的普遍青睐与认可。

2.2.1 PID 控制基本原理

PID 此名词是由英文中比例（Proportion）、积分(Integral)、微分(Differential coefficient)这三个单词的首字母 P、I、D 组合而成，这三个词表示的是三种调控方式。PID 控制器是由这三种方法组成的一个在控制领域被广泛使用的并联控制器，它能将这三种方法结合起来并以调谐控制过程中误差的方式使被控系统趋于稳定。如温室大棚温度控制这种过程控制模型，有关人士常常使用 PID 控制器进行调控。通常情况下，一个控制系统都会至少涵盖一个常规 PID 控制器以及一个实际的被调控对象^[32, 33]。常规 PID 控制器的调控原理如图 2-2 所示。被控参数实际值与设定值的误差作为控制器输入，经过比例、积分、微分计算调节后，输出该系统的控制量并作用于被控对象以达到闭环调控的目的。




图 2-2 PID 控制器原理图

Fig 2-2 PID controller schematic diagram

PID 温度控制器在调控过程中的控制偏差是由温控系统的设定温度与系统实际输出温度的差值构成：

$$e(t) = r(t) - y(t) \quad (2-8)$$

上述公式中， $r(t)$ 是对控制系统所给定的一个目标值（设定值）， $y(t)$ 则是系统当前的实际输出值。

PID 控制器其控制规律的数学模型为：

$$u(t) = K_p \left[e(t) + \frac{1}{T_i} \int e(t) dt + \frac{T_d de(t)}{dt} \right] \quad (2-9)$$

也可将此式写为传递函数形式：

$$G(s) = \frac{U(s)}{E(s)} = K_p \left(1 + \frac{1}{T_i S} + T_d S \right) \quad (2-10)$$

公式（2-9）、公式（2-10）中 K_p 是控制器的比例系数， T_i 是积分时间常数， T_d 为微分时间常数。

事实上，PID 控制器的调节效果很大程度上受控制系统中三个参数的影响，所以对参数的选择至关重要。PID 控制器中各校正环节参数的作用如下：

（1）比例环节

PID 控制器比例环节类似一个可调节扩大倍数的扩充机制，其数学公式表示如下：

$$\Delta p = k_p * e \quad (2-11)$$

此式中， k_p 为控制系统的比例增益， e 为控制系统的输入参数——系统偏差（控制器实际值与设定目标值之间的差值）。当控制系统中产生偏差信号时，比例环节能够将其成比例地反映，同时不断地对控制系统进行调控以降低系统偏差。不同比例系

数的选取会对控制系统的调控效果产生很大的影响。比例系数的扩大，能够将系统过渡过程的时间减少，加快系统的调控速度，同时也能减小稳态误差，实现更高精度地调控。然而如果 kp 过大，会产生较大的超调量，以至控制系统大幅振荡，难以保持稳定。反之，如果 kp 的值过小则会减小系统的超调量，提高其稳态裕度，从而导致系统的调控速度变缓，系统的调控精度也逐渐走低，调控效果变差。所以在实际的调控过程中，我们在开始阶段 kp 应选择较小的参数，以尽量降低其他干扰因素（如物理量的变化）的影响；到了控制过程的中期时，将 kp 的值增大，从而增强控制系统的精确性以及快速响应特性；而在控制过程的最后阶段，又应该将 kp 值适量降低，以防产生过大的超调导致系统振荡而难以稳定，提高控制系统的稳态精度。从以上调控过程来看，比例调节于整个控制系统而言，只是对其实施了一个初步的粗调，然而在这个过程中其实还会产生比例环节难以处理的余差，此时就要用到积分环节将其消解。

（2）积分环节

公式（2-12）为 PID 控制器积分环节的数学公式：

$$\frac{K_p}{T_i} \int e(t) dt \quad (2-12)$$

从此数学表达式中可以看出，当控制系统始终难以达到设定的目标值，即在控制系统中只要有控制偏差存在，控制器的积分环节就会不停地将积分作用累积，再将实际的控制量输出以达到消除系统的静态偏差值的目的。

然而积分环节具有大滞后性的特点，这会导致控制系统的响应速度逐渐变缓。积分时间常数 T_i 直接决定了控制系统中积分作用的强弱，当 T_i 数值较大时，积分作用会相对较弱；反之，当 T_i 较小时，控制器的积分作用就会较强，过强的积分作用也会导致系统产生较大的超调量从而引发振荡，不利于闭环系统的稳定。所以在实际的调控过程中，同样应考虑不同阶段 T_i 的大小对控制系统性能优劣的影响以确定它的取值。值得一提的是，在控制器中加入了积分环节之后，为了使闭环系统趋于稳定，我们可以将比例环节的系数 K_p 适当地减小。

（3）微分环节

微分环节的作用是：它能很好地反馈出该闭环控制系统中偏差信号 $e(t)$ 的变化趋势，当偏差信号一直增大乃至趋于一个过高的值之前，该环节向控制器提供一个早期信号，此信号能对控制系统进行合理修正，以此减少调控时间，提高实际调控的效率。微分环节能有效地改善被控对象因大滞后特性给实际调控带来的不利影响^[34]，合适的微分时间常数的选择除了能加快系统的响应速度之外，还能抑制调控过程的剧烈振荡，控制可能急剧提高的超调量，使系统趋于稳定。如果微分作用过强，通常会减弱控制系统的抗干扰能力，由此对控制系统的安全性产生不利的影响。所以实际进行工农业

调控时也应根据调控的不同阶段来选择合适的微分时间常数,以求控制系统能达到最佳的调控效果^[35]。

2.2.2 PID 参数整定的研究

由于 PID 控制器在工农业控制领域的广泛应用,研究人员一直在致力于对 P、I、D 参数整定方法的深度探索。PID 控制器中各参数的整定与其自适应方法的优化一定程度上代表了 PID 控制器的发展历程。

国内外很早开始就利用不同的技术以对 PID 控制器参数实现自动或手动整定(如 Ziegler 和 Nichol 提出的 ZN 法)。早期一般都是用传统的方式进行常规 PID 参数整定,到后来逐渐发展为利用现代计算机技术在控制领域进行智能化 PID 参数整定。近些年来,对于 PID 控制器参数整定方法的实践探究主要体现在如下几个方面,如果依照控制系统中的被控对象的数量划分,有两种 PID 控制器参数整定方式。一种为单变量 PID 参数整定,此种方式涵盖了实际应用领域中大量的 PID 参数整定方法。另一种则是多变量 PID 参数整定,这种方式引起了近些年来各领域研究人员的强烈关注。倘若根据对控制量的组合形式划分又可分为两种:一种是线性 PID 参数整定方法,此方法一般用于传统 PID 控制器中;另一种是非线性 PID 参数整定方法,此方法通常作用于一些较为复杂的控制系统,如由非线性跟踪—微分器与非线性组合方式相结合产生的非线性 PID 控制器^[36]。在 PID 控制的发展历程中,传统的 PID 参数整定方法多数都需要人工将被控对象的特征参数在实际进行调控之前预先提取,其次再依照经验公式进行数学运算。此类方法大都适合于手工离线的 PID 参数整定^[37]。

2.2.3 PID 控制的评价指标

对于任意不同的控制器、控制算法,都应有一套合适的衡量其算法优劣的标准,此标准在一定意义上代表了控制系统的性能与价值。PID 控制器的评价标准(即性能指标)就能较为直观地呈现出控制系统的效率以及调控过程中控制器实时的工作状态。当下,对于 PID 控制器,我们衡量其性能的评价指标主要有:动态性能指标、静态性能指标此两种形式。在一般情况下, PID 控制器常有以下动静态性能指标:

调节时间,一般指的是控制系统在达到控制目标(即研究人员给被控对象参数的设定值)或稳定在目标值上下 2% 的范围内所消耗的时间。调节时间的长短在一定意义上代表了控制器响应速度的快慢,当系统调节时间相对较短时,通常认为控制系统的调控性能较好,调控效率较高。

超调量,此指标一般为控制系统的响应曲线中被控变量波形的最大峰值与实际设定目标值的差值。超调量在一定程度上代表了控制系统调控的最大偏离程度,也是一项能很好反映调控效果的关键指标。

稳态误差,稳态一般指的是控制系统中被控对象的响应曲线在调控的过渡过程结

束后在某一范围上下稳定浮动的状态。系统在此状态下实际输出量与期望输出量（设定的目标值）之间的差值即被称为稳态误差。稳态误差一般可视为控制系统的一个静态指标，当系统的稳态误差较小时，我们可认为控制器有了一个较高的调控精度，调控水平达到了一个较高的水准。

下图为某系统的单位阶跃响应图，此图中较为清晰地标注出了上述评价指标。

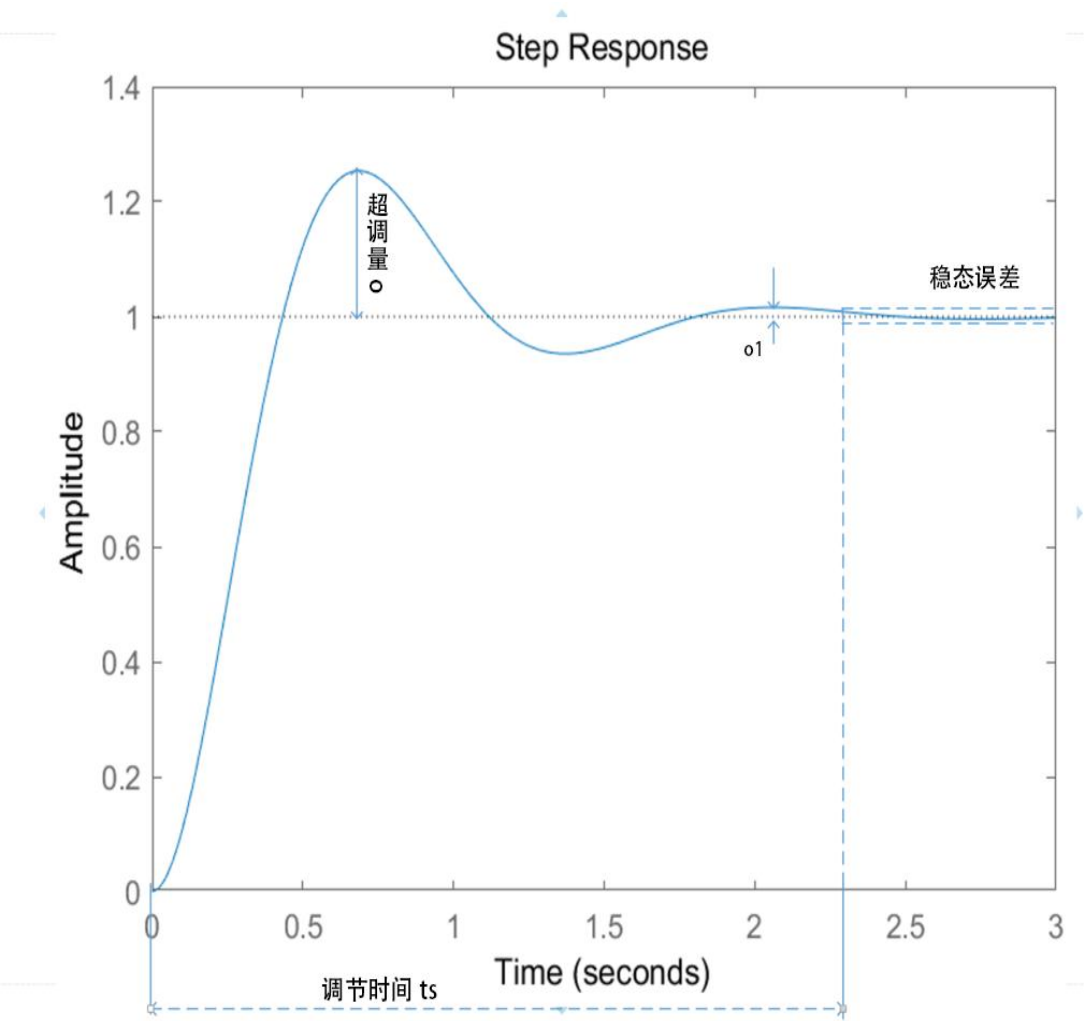


图 2-3 系统单位阶跃响应及其 PID 评价指标图

Fig 2-3 System unit step response and PID evaluation index diagram

2.3 ZN 法整定 PID 参数调控温室大棚温度

2.3.1 ZN 临界比例度法方法简介

1942 年，一种经典的 PID 控制器参数整定方法问世，此方法由 Ziegler 和 Nichols 共同探索研究并提出，自此便得到各界研究人士的广泛关注并被研究人员频繁应用在工农业的控制领域，该方法就是著名的 Zigler-Nichols 临界比例度法^[38]。ZN 临界比例

度法是一种并不依赖于被控系统数学模型实际参数的闭环回路整定方法,它是在满足一定的工业生产调控的条件下,对控制系统进行纯比例控制,当被控系统到达临界振荡的阶段时,获得此阶段中能够确定被控系统动态特性的两个参数并将这两个参数带入两人提出的经验整定公式再而计算出 PID 控制的最优整定参数。在此方法中起到关键作用的两个参数是:临界比例增益 K_u 与临界振荡周期 T_u 。

此方法的具体调控流程如下:

(1) 在系统进行闭环调控的过程中,当系统的被控变量到达稳态或很接近稳态,将 PID 控制器的积分作用和微分作用剔除,仅维持比例作用,调整比例增益参数 K_p 将其设为一个相对较小的值,使控制系统保持向后运行。

(2) 将系统的比例增益参数 K_p 缓缓增大,同时在系统中给定一个较小的被控参数数值,此阶段系统的被控变量值会逐渐与最初设定的目标值偏离,随后以一个较小的增幅将 K_p 的值慢慢提高,使闭环控制系统的响应曲线由开始阶段的衰减振荡状态循序转变为等幅振荡状态。当 K_p 增长为一个较大值,被控系统的响应曲线呈现出增幅振荡状态时意味着对于比例增益参数的调整量过大,此时应将 K_p 值反向减小,从而让控制系统的响应曲线重新回归至等幅振荡状态。

(3) 观察系统的闭环响应曲线,记录等幅振荡状态下被控系统的两个关键参数(临界比例增益 K_u 、临界振荡周期 T_u),而后再根据实际的控制器类型,将参数带入表 2-1 中的经验整定公式,计算得到 PID 控制器参数经整定后的优化值。

(4) 在实际的控制系统中调用经 ZN 临界比例度法整定后的 PID 参数值,给定一个被控变量的目标值,再让系统进行闭环调控。仔细观察系统的调控过程并通过系统的响应曲线简单计算出能够衡量调控效果的各指标数值,判断其是否能达到实际调控前预设的性能标准,如若能达到则意味着此整定方法成功优化了 PID 控制器参数;如若不能达到,则应舍弃此次控制器的整定结果,继续进行下一次的 PID 参数整定。

2.3.2 仿真研究

利用上述章节得到的温室大棚温控模型,在 Python 中编码构建此模型的数字模拟仿真环境(将此动态数学模型与控制器算法结合的时阈离散模型),数值模拟器原理图如图 2-4 所示。在每个时间步内,将施加于模拟加热器上的电压注入温室大棚模型从而获得下一个时间步的实际温度。再通过处理控制算法,将当前温度与设定的目标温度作为输入,以得到系统下一时间步的电压,基于此原理,数字模拟器在采样时间内逐步操作。




图 2-4 数字模拟器原理图

Fig 2-4 Schematic diagram of digital simulator

设定调控的目标温度为 37 度，系统初始温度为 5 度，采样时间为 600s,采样时间间隔为 1s。调控过程中首先将比例增益系数 K_p 缓缓增大，记录下系统闭环响应开始不断振荡阶段的关键参数，可知系统的临界振荡增益参数为 0.77，系统的振荡周期是 30.8s。

在程序中通过 K_u 与 T_u 的值，结合表 2-1 所给出的 ZN 临界比例度法的 PID 控制器参数整定公式进行计算，可得整定后的参数值为：

$$K_p=0.46, T_i=15.4, T_d=3.85。$$

表 2-1 ZN 临界比例度法对不同类型控制的参数整定表

Tab 2-1 Parameters tuning table of ZN critical scaling method for different types of control

调节规律	K_p	T_i	T_d
P	$0.5 K_u$		
PI	$0.45 K_u$	$0.85 T_u$	
PID	$0.6 K_u$	$0.5 T_u$	$0.125 T_u$

系统的闭环响应曲线如图 2-5 所示：




图 2-5 系统闭环响应曲线

Fig 2.5 System closed-loop response curve

控制系统的仿真结果，如表 2-2 所示。

表 2-2 ZN 法控制仿真结果表

Tab 2-2 ZN method control simulation results table

调控方法	超调量 (°C)	平均稳态误差 (°C)	最大稳态误差 (°C)	调控时间 (s)
ZN 法	12.85	1.68e-10	2.5e-09	156

由控制系统的仿真结果与响应曲线可看出，使用 ZN 法整定 PID 参数进而实现温室大棚温控的过程在第 156 秒到达预先设定的目标温度，调控速度较为缓慢，振荡幅度较大，系统进入稳态时稳态误差很小，平均稳态误差约为 1.68e-10，最大稳态误差约为 2.5e-09，此方法调控过程中超调量较大，约为 12.85 左右。

2.3.3 ZN 临界比例度法的缺点

尽管 ZN 临界比例度法在工农业控制领域的应用相当宽泛，且它的实现（整定 PID 参数的过程）并不复杂，但是此方法也存在小部分缺陷，主要体现在以下几个方面：

（1）一般情况下对于具有大时延的滞后系统而言，ZN 法对 PID 参数的整定需要进行大量的振荡实验，然而在实际工农业控制的某些领域中，常常会杜绝控制系统产生临界振荡的现象，因为该现象的产生有时候会引发控制系统崩溃，而且控制系统的动态响应过程实际上异常缓慢，此时 PID 参数的整定过程会耗费过长的时间从而导致系统难以取得较为理想的控制效果，使工农业生产的效率降低，产量减少。

（2）在使用 ZN 法整定 PID 控制器参数时，通常情况下，如果研究人员手动将比例增益系数 K_p 增大，那么系统响应的振幅实际上也会随着 K_p 的变化相应的扩大，同理，减小 K_p ，振幅亦会相应减小。然而，某些特定情况的发生会导致即使调控 K_p 参数也不会任何程度上影响系统振荡幅值的大小。此种现象出现时常常引发工作人员的错误判断，误认为被控对象已经处于临界振荡状态而得到不正确的 K_u 与 T_u ，使计算整定后 PID 控制器参数的最终结果误差过大。

（3）在控制系统处于稳态或到达稳定的边界时间点时，系统响应连续不断的振荡。倘若此时控制系统外部产生扰动反应或者内部产生未预料的过程变化，极有可能破坏系统的稳定性。不仅如此，多次手动现场实验获取数据的过程中某些因素（如操作不当）也会使数据附带着极大的噪声并由此对调控效果产生十分不利的影响。

2.4 遗传算法

2.4.1 遗传算法的理论提出

自然世界中的一切事物都是依靠着对外部复杂环境强大的自适应与自调整能力，才得以生生不息地向下繁衍至今。各领域研究人员基于自然界物种进化过程，对生物演化的机理、演变规则进行大量的深度研究与探索，并尝试在其中引入现代计算机技术，融合其机理且将其拓入工农业领域中的人工自适应理论，对工农业控制的智能化、现代化产生了深远的影响^[39]。最早对物种进化过程的自然机理进行研究并尝试将其引至人工自适应理论的人是 Holland^[40]教授，1967 年他在密执安大学任教时便开始进行此领域的探索，其学生 Bagley 在这一年首次提出了“遗传算法”这一专业术语并探讨了它在博弈论领域应用的可能性，然此研究受限于初期的条件制约（可指导理论过少、可用于科学计算的工具不完备）。20 世纪 70 年代，De Jong^[41]受自然界生物繁衍、进化、遗传的影响，逐渐开始利用其机理并尝试大量的实验（主要用于函数优化以及计算机系统仿真）。到了 20 世纪 80 年代时，经过大量仿真对比实验的经验获取与总结梳理，Godiberg 与相关领域的学者初步整理出了遗传算法的基本框架，这也是遗传

算法的雏形。再往后，遗传算法便进入了高速发展的时代。

由于遗传算法极佳的抗干扰性能与良好的适应能力，它被各界工程应用人员与研究学者引入到现实生活中的多个领域中，比如工农业控制、交通道路规划、函数优化、智能家居、图像识别、机器学习等等。总而言之，对遗传算法领域的不断深耕探究已然使它成为实际生产生活中一个极度高效的科学研究工具，这将毫无疑问会在未来进一步推动科技的发展。

2.4.2 遗传算法的概念

遗传算法（Genetic Algorithm，简称 GA）^[42]的机理源自于对生物在自然世界中遗传进化过程的探究，是一种对此过程进行了模拟的迭代式概率搜索算法，可处理全局最优化问题。它基于生物朝下一代繁衍的方式，将某类问题的候选解以种群个体中染色体的形式抽象表示，在下迭代的过程中，染色体会经过遗传、突变、自然选择、杂交等操作，但是会保留一部分遗传信息，再迭代为新的染色体。以一个特定的参数指标为衡量其优劣的标准，并基于此标准对不同的染色体进行筛选，最终得到能够很好适应设定条件的最佳染色体编码。这种如物种进化过程中在优胜劣汰、适者生存的条件下诞生的新一代种群往往会比前一代种群在苛刻的外部环境下更易生存，一代一代进化，子代会集中至更好的搜索空间中，也就意味着后代种群会向一个最优区域集中，这个区域中的解集被称之为问题的近似最优解^[43]。

遗传算法中染色体的构成数据结构是一组或多组数组，数组中不同位置所存放的数据表示不同的遗传信息，当待处理问题并不复杂时，通常用一串结构数据组成基本染色体编码。个体中染色体由大量基因按顺序排列组合而成，此类个体通常被称为基因型个体。数量较多的基因型个体形成了遗传算法中的问题求解种群。组成种群的基因型个体数量代表的即是种群的大小，通常将其称为群体规模^[44]。

最早对于一些传统的最优解问题，一般通用的几种解决方法是采用搜索算法、启发式算法、枚举法等算法。然而由于不同类型待求解问题的越来越多，问题设定条件的愈加复杂，此类方法在一定程度上满足不了日益繁杂的需求，而遗传算法不仅具有极佳的自组织、自适应特性^[45]，而且没有对于搜索空间知识及相关辅助信息的特定需求。使用适应度函数值作为标准以对新世代个体进行评价筛选，对于寻优搜索的方向则是以概率的变迁规则进行指导，逐步向下迭代，从而针对提出的问题得到一定量的极优解。这些特性让遗传算法成为解决某些较复杂问题的新思路，同时使其拥有更广的通用性和更加宽泛的应用范围。

2.4.3 遗传算法的关键技术

（1）编码

一定数量的经过基因编码的个体构成了遗传算法的初始化种群，种群中任意个体

都存放着特有的遗传信息（由一个可被称为基因组或染色体的变量序列表示），故而各个体都一定的可能性成为待解决问题的优解。

遗传算法在搜索目标问题的可行解之前，会将解空间变换为易于算法处理的搜索域形式（常以基因型串结构数据表示），这种转换方法即被称之为编码。使用不同方式编码会在一定程度上对算法处理过程中的交叉、变异运算产生不同的影响，倘若某编码方式对当前问题的实际条件与情况并不适用，极有可能降低算法执行效率，使处理结果难以达到预定的标准。

当下编码方式很多，被频繁用到的几种为：二进制编码、浮点数编码、格雷码编码、排列编码等^[46]。研究人员受益于染色体结构，对种群中个体染色体的表示采取由二进制符号 0、1 组合而成的二值符号集 $\{0, 1\}$ 的形式，此编码方式即为二进制编码^[47]。使用二进制编码的优点有：简易，不管进行是编码或解码都异常方便快捷；有利于遗传算法中交叉、变异等操作的进行；符合最小字符集编码原则。然而对于连续函数的离散化操作，二进制编码的使用可能会产生映射误差。如果使用格雷码编码则会强化算法的对应局部搜索能力，为连续函数的局部搜索问题带来极大的便利。对连续参数的优化通常使用的是拥有良好精度的浮点数（实数）编码。排列编码的优点是简洁直观、易于理解，通常被用来处理 TSP(旅行商)问题。现实环境中选择编码的方式应具体问题具体分析，针对不同的问题场景使用更适宜于处理此类问题的编码，以此提高效率。

（2）适应度函数

通常用适应度函数来衡量种群中个体对于环境的适应情况，把环境中个体适应状况的量化值称为适应度。遗传算法中，适应度较高的个体通常有更大的概率往下一代遗传，即可以使用适应度的大小对一定条件下个体的优劣进行判别。适应度函数是遗传算法向下搜索寻优过程的最为关键的指标，不合理适应度函数的选取通常会大大减缓算法的收敛速度，降低算法执行的效率，使算法时间复杂度过大。所以，设计遗传算法时应尽量将适应度函数简化从而改善算法执行的效果。

（3）选择策略

选择操作是指在当前代的种群中筛选出适应度较高的基因型个体，将其作为父代进而繁衍出优良的下一代群体。适应度越高，一定程度上代表个体生存特性越强，个体有更大的概率存活下来。此操作类似于自然界物种进化过程中优胜劣汰的过程，与“适者生存”的法则相符合。较常使用的选择策略有：轮盘赌选择法^[48]、锦标赛选择法、随机遍历抽样法等。

轮盘赌选择法：此方法通过种群中单个个体的适应度对该个体可能在子代出现的概率（此概率与个体适应值成比例）进行计算，再以此概率执行选择操作经过遗传繁衍出新一代种群。在使用此策略时，设定种群大小为 Z ，当前代里第 i 个基因型个体

的适应度值是 $f(i)$ ，那么筛选此个体的概率 Z_i 是：

$$Z_i = \frac{f(i)}{\sum_{j=1}^Z f(j)} \quad (2-13)$$

Z_i 代表个体适应度在种群内部占种群累积适应度之和的比例，当个体适应度处于一个较高值时，意味着此个体极易被筛选，反之，个体适应度如果较低，那么被筛选的概率也就越低。实际进化时，某代中的最优解存在一定的可能性发生交叉或变异，进而引发退化的情况。倘若向下一代进化时，直接将种群内适应度最高的个体保留，则极有可能陷入局部最优解现象。

锦标赛选择法：此选择策略是在进化时对种群中一定数量的个体每次都进行适应度的比较，筛选出适应度最高的个体保留至下一代中，类似一种“放回抽样”的方式，重复进行此操作直至满足筛选条件的个体达到给定数量的要求^[49]。此方法具有较强的随机性，可能会产生较大的随机误差。

随机遍历抽样法：首先给定一个概率，将此概率作为最小化波动概率的形式再进行个体选择。此方法类似于一种轮盘赌游戏，轮盘上划分多个等间距的点，在等距间隔内使用一个随机值在轮盘上进行旋转选择个体。相较于其他选择策略，此方法对于适应度较低的个体也存在选择的可能性，即对“不公平性”给予了奖励。

(4) 交叉

交叉是遗传算法进化新生个体的主要方式之一，对算法的向下进化至关重要。交叉是父代中的染色体中一定的遗传信息进行交换、重组从而形成新的染色体个体的操作。父代中的两个个体按照交叉率随机交换某些优质的基因形成新的基因型组合。遗传算法中采用二进制方式编码时，通常较多用到的交叉算子是一点交叉、两点交叉与均匀交叉。经过交叉后的子代个体常常将父代个体中的优点两相结合。

(5) 变异

变异算子常常用以对基因突变使种群中产生新个体这一现象进行描述，此现象发生的概率极小。一般先使用随机的方式将某个个体选出，其次再采取某特定的概率将个体数组内部某一个位置存放的数字替换，最后再产生一个新的遗传算子。变异操作不仅能抑制未成熟收敛现象的产生，而且也体现了遗传算法中物种进化的多样性。由于种群规模、染色体长度等因素都会对变异率产生一定的影响，所以通常将变异率取一个较小值，范围在 0.001~0.4 之间。遗传算法中较常用到的变异方式有基本位变异、均匀变异以及非均匀变异。使用不同的编码方式所采取的变异方法有所不同，对于二进制编码常用的变异方法为二进制变异，而在采用实数编码时，一般使用的变异方法为均匀变异或非均匀变异。

交叉和变异操作在相互配合的同时又相互制约，使遗传算法无论是在局部又或是

在全局都能保持优秀且均衡的搜索能力。

2.4.4 遗传算法的基本流程

遗传算法执行时，第一步对实际问题进行分析以确定该问题的参数集，再根据实际问题参数集选择合适的编码方式，设定合理的评价标准对适应度函数进行评价，随机生成初始化种群，再采用适应度函数评价种群个体，评价结束后再经过选择、交叉与变异等操作衍生出下一代个体。循环往复进行此操作，直到最后能得到问题的最优解或向问题的最优解逼近。下列步骤为遗传算法的基本执行过程：

- (1) 首先根据问题对对象进行编码，以随机的方式初始化种群。
- (2) 对种群中每个个体的适应度值进行评价计算
- (3) 判断是否能满足设定的终止条件，如若满足则终止，如若不满足则进行步骤 (4)。
- (4) 将种群中个体向下一代进化时被复制的概率确定，使用选择、交叉、变异等遗传算子对种群进行操作，从而产生新的种群。继续进行步骤 (2)。

遗传算法基本流程图如下图所示：




图 2-6 遗传算法基本流程图

Fig 2.6 Basic flow chart of genetic algorithm

2.5 基于 GA-PID 调控温室大棚温度

在 PID 温控系统中, 对比例参数、积分参数、微分参数的选取是优化控制器调控效果的关键。对于实际生产生活中的不同系统, P、I、D 三个参数通常并非都是选择固定的数值以供使用, 与 ZN 法类似的一些过于依靠人工经验、需要不断进行手动凑试的 PID 参数调控方法常常会耗费工时, 且仅仅通过缓慢摸索选定参数往往会造成控制器调控效率低下, 难以令人满意。而由于遗传算法不需要初始值便能够进行自动寻优, 并且可以朝特定目标进行优化, 所以可使用遗传算法来优化 PID 控制参数以实现温室大棚温控。(即以 GA-PID 调控温室大棚温度)

使用遗传算法整定 PID 控制器的参数有较多的优点。常用的一些寻优算法通常对于初始值的要求较高, 而遗传算法的自动寻优能力能很好地克服此缺点; 当初始条件难以满足或选取不当时, 遗传算法仍能搜寻正确的参数, 以达到控制器的调控目标; 遗传算法相较于传统的依赖于大量规则的 PID 控制器参数整定方法, 其整定速度更快、效率更高、对各种繁杂规则的依赖性较低, 且很大程度地免除了一类繁琐的操作(如初期规则的制定、知识存库的累积等)所需要耗费的大量时间; 遗传算法的优势还在于它除了能对单值进行最优搜索之外, 而且可针对多值进行处理。不管是针对相同或不同控制系统里的单值又或是多值问题, 遗传算法都能很好的在预先设定好的范围条件下搜寻到待处理问题的最优参数集。以下为遗传算法优化 PID 控制器参数 K_p 、 K_i 、 K_d (GA-PID) 的基本步骤^[50]:

- (1) 设定待处理问题中参数的取值范围并对参数进行编码;
- (2) 对一定数量的个体随机构建为初始种群 $P(0)$;
- (3) 对种群中各个体进行解码以获取各个体所对应的参数值, 在利用该参数值计算求解算法的适应度函数 f 与目标函数 J , 其中 $f = 1/J$;
- (4) 对本代种群进行复制、选择、交叉、变异等操作。本代种群进化得到新一代种群;
- (5) 判断参数是否收敛或算法是否已达到设定目标(即是否已满足终止条件), 如果是, 则算法终止, 跳出循环; 如果不是, 则重复循环进行步骤(3)与步骤(4)。

将控制对象引入与上述 ZN 法相同的 Python 数字模拟仿真环境中, 控制器选定遗传算法。设定调控的目标温度为 37 度, 初始温度为 5 度, 采样时间为 600s, 采样时间间隔为 1s。添加平方项至目标函数以实现对控制量大小的调控, 本算法性能评价指标如下所示:

$$J = \int_0^{\infty} (\omega_1 |e(t)| + \omega_2 u^2(t)) dt \quad (2-14)$$

此式中, $e(t)$ 表示误差, $u(t)$ 表示控制量, t 代表控制器的调节时间, ω_1, ω_2 表示

权重。为了抑制超调现象的出现导致系统的稳定性遭到破坏，采取惩罚措施，将超调量作为一项关键参数加入到系统的性能评价指标式之间，即当超调存在时，控制系统的性能评价指标式如下：

$$\text{if } ey(t) < 0, \quad J = \int_0^{\infty} (\omega_1 |e(t)| + \omega_2 u^2(t) + \omega_3 |ey(t)|) dt \quad (2-15)$$

该式中， ω_3 仍是加权值，且其值大于 ω_1 ， $ey(t)$ 则表示超调，有 $ey(t) = y(t) - y(t-1)$ 。因为 kp 、 ki 、 kd 这三个参数的取值在很大程度上会影响温室大棚温度的调控效果，所以如果我们以 $Func$ 函数来表述控制系统的性能指标，那么性能指标 J 可以使用以下的关系式表示：

$$J = Func(kp, ki, kd) \quad (2-16)$$

采取的编码方式是实数编码，设定种群中的个体数量为 50，交叉的概率选取值为 0.8，变异率为 0.33，决策变量参数 kp 、 ki 、 kd 的寻优范围均设为 $[0,1]$ ， ω_1 取 $e^{0.001}$ ， ω_2 取 0.001， ω_3 取 15。在遗传算法向下执行进化 50 代之后，得到 PID 控制器的参数整定结果为 $kp=0.27, ki=0.93, kd=0.22$ ，进化后的算法性能指标 J 约为 10.31。系统性能指标的搜索寻优曲线图以及实际仿真的闭环响应曲线如下所示：




图 2-7 性能指标 J 的优化过程曲线图

Fig 2-7 Optimization process curve of performance index J

由图 2-7（性能指标 J 的优化曲线）可看出，本种群的时间误差积分函数值在第 1 代至第 8 代的迭代过程中迅速下降，表明算法执行种群的适应度在此期间迅速提高，迭代的中后期至最终代阶段 J 仍保持缓慢下降并在最终代得到一个极小值，意味着遗传在进化终止时得到预设问题的近似最优解。




图 2-8 系统闭环仿真调控过程曲线图

Fig 2-8 System closed-loop simulation control process curve

表 2-3 (GA)遗传算法仿真调控结果表

Tab 2-3 (GA) Genetic algorithm simulation control results table

调控方法	超调量 (°C)	平均稳态误差 (°C)	最大稳态误差 (°C)	调控时间 (s)
遗传算法 (GA-PID)	5.19	3.72e-11	1.1e-10	96

在图 2-8 中，虚线表示的是控制系统中设定的目标温度，实线代表的是使用遗传算法整定 PID 控制器参数后闭环系统的响应曲线。由图可看出，控制系统的超调量较小，调控过程达到预设目标温度所需的时间较短，稳态误差趋近于 0。结合图与程序的仿真结果（表 2-3）可知，经过遗传算法整定后的 PID 控制器（GA-PID），超调量约为 5.19，系统平均稳态误差约为 3.72×10^{-11} ，最大稳态误差约为 1.1×10^{-10} ，在时间为 96s 左右达到稳态。

2.6 实验结果对比分析

表 2-4 为分别使用传统的 ZN 法与使用遗传算法整定 PID 控制器参数从而实现温室大棚温度调控的仿真效果对比表。由此表可明显看出,使用 ZN 法整定 PID 参数的调控方式超调量较为明显,振荡程度较大,响应速度较慢,稳态误差很小;相比之下,使用遗传算法整定 PID 参数的调控方式超调量显著降低,稳态误差进一步减小,保持着较好的稳定性,控制系统响应较快,达到设定的目标温度的调控时间明显减少,比起 ZN 法的 156 秒,其在 96 秒的时间内便达到稳态。因此,我们可以得出结论:在给定的一个理想环境下,利用遗传算法整定 PID 参数以实现温室大棚温度控制的方法不仅能合理有效地减小超调量、振荡幅度、调控时间和稳态误差,且在响应速度等方面也明显优于使用 ZN 法整定 PID 参数以实现温室大棚温控的方式。

表 2-4 ZN 法与遗传算法仿真效果对比表

Tab 2-4 Comparison table of simulation results between ZN method and genetic algorithm

调控方法	超调量 (°C)	平均稳态误差 (°C)	最大稳态误差 (°C)	调控时间 (s)
ZN 法	12.85	1.68e-10	2.5e-09	156
遗传算法	5.19	3.72e-11	1.1e-10	96

2.7 小结

本章首先基于当前环境下温室大棚的阶跃响应曲线利用两点拟合算法得温室大棚的动态模型。然后介绍了传统的常规 PID 控制,在此部分较详细地阐述了 PID 控制器的基本调控原理、PID 控制器的几类参数整定方法、PID 控制器调控效果的几种评价指标等。接着提出了使用 ZN 法整定 PID 参数以对农业温室大棚进行温度调控,此部分先是对 ZN 临界比例度法进行了简要叙述,其次再针对此方法在基于此温室大棚温度模型的仿真环境下进行了仿真调控,也简单介绍了 ZN 法的一些缺点与不足。最后一部分又提出了利用遗传算法优化 PID 参数进行温室大棚温度调控,此部分的开头同样是对遗传算法的概念、相关技术与基本流程进行了详细讲解,再在相同的环境下使用 Python 对 GA-PID 调控温室大棚温度进行仿真,对以上两种方法的仿真调控效果做了对比分析,最终得到了在给定的环境下,使用遗传算法整定 PID 参数进行温室大棚温度控制比之 ZN 法具有更大的优势的结论。

3 基于 GA-MPIDNN 算法的温室大棚温度控制

温室大棚系统的外部气候环境常会不断变化,内部农作物环境的多种参数(如温度、湿度、CO₂浓度、光照强度、氧气浓度)都具有强耦合性、难以剥离^[51],造成了温室大棚系统温度不易稳定调控的特点。由于温室大棚系统不仅具有大滞后、大惯性、强干扰等特性^[52],而且是一种非线性、易受内外部各类环境因素影响的复杂系统,传统的 ZN 法、遗传算法整定 PID 控制器参数来进行温室大棚控温都很难达到理想的调控效果,尤其是当控制系统受外界环境变化或非线性因素影响时,使用此类方法优化后的 PID 控制器参数一般无法随着这些变化继续优化而改变^[53],由此难以满足研究人员期望高性能、高精度、高效率调控的要求。于是,研究者尝试将神经网络引入 PID 控制器参数的整定,将神经网络与 PID 控制器相结合,利用神经网络强大的非线性逼近能力、自学习、自组织、自适应调整特性,使 PID 控制器在大时延、高度耦合的环境下仍具有极佳的静态性能与动态性能^[54]。

3.1 神经网络

3.1.1 神经网络的基本理论

神经网络是一种模拟了生物学上的人脑功能,能够进行大规模信息处理的并行分布式处理系统。神经网络技术基于人脑部神经元特性,对人的智能化行为进行探索,进而模拟人脑处理接收到的外界反馈的各类信息。利用神经网络进行智能化调控是工业界控制领域中极为关键的一个分支,组成神经网络的基本单位是神经元,多个神经元以一种特定的方式互联构成强大的自适应动态神经网络系统^[55]。各神经元间不同的连接形式会对神经网络的功能与特性产生较大的影响,神经网络内部包括多个不同的领域和部门,其互联模式也存在着较大的差异。神经网络的探究涵盖了多类学科(如计算机科学、控制工程、生物医学、物理学、微电子学、统计学等等),因此其发展也会促进现代科学在诸多领域的应用。神经网络极为优越的一个特点是在确定了某对象输入与输出空间信息的情况下,无需对对象进行具体的数学建模,便能以某个任意的精度将输入端到输出端信息之间的特定关系建立。神经网络凭借其对非线性系统良好的逼近能力,能够对某些不确定的模糊语言或者视觉信息问题进行有效处理,它对信息的存储与调度是通过并行或分布式的处理方式,其容错性强且响应速度迅速,效率极高。神经网络的良好性能使其去除了传统方法过于依赖经验、无法自适应调整等缺点,在当下的专家系统、系统辨识、智能控制等多个现代化科研领域都被成功运用。在工业控制领域,神经网络的一些显著优点^[56]有:

(1) 非线性映射特性

神经网络可对复杂的非线性问题进行有效处理,利用自身对非线性函数的强逼近

能力,形成某个不确定对象的非线性动力学系统,并以此来对该对象的结构类型或控制器类型进行表示。神经网络可以以一个任意精度针对某对象建模的特点,使之在系统辨识领域拥有得天独厚的优势。选定一个合适的神经网络,将目标辨识对象的激励信号和响应信号输入其中,经过多次学习训练,神经网络会以极高的精度向对象趋近。神经网络对于对象的辨识相比之于其他方法,其准确性强、精度更高,且在经济性、实用性方面更好。

(2) 高度并行分布式处理能力

神经网络内部由诸多神经元形成的互联结构使之具有强大的高度并行式处理能力,可使其在处理复杂问题时在资源条件有限的情况下依旧能通过高速运算迅速寻找到优化解,具有很好的容错性^[57]。

(3) 自学习、自组织、自适应特性

神经网络具有良好的自适应、自学习特性,是一种能够不断通过学习训练来进行参数调整的动态系统。当内外部环境变化导致控制系统结构、参数发生改变时,神经网络具有根据变化自适应调整控制参数从而让控制系统保持稳定的能力,也称为自适应控制能力。

(4) 适应多输入多输出系统的能力

在多输入多输出信号的系统中,神经网络凭借内部并行的网络结构带来的高效处理数据的能力也能很好地适应于其中。

(5) 泛化功能

对于某些未经训练或含有复杂噪声的数据样本,神经网络也能对其进行有效处理并得到合适的解答,将信息分布存储于内部的不同神经元之中,使系统具备良好的稳定性、鲁棒性以及容错性。

3.1.2 神经网络的应用领域

神经网络能够利用其非线性逼近、自适应、自调整、自学习归纳等优良特性来处理现代科技领域中诸多难以解决的复杂问题,对问题进行合理的判断并提供合适的处理方案。人工神经网络技术在现实世界的实际生产生活中主要应用在如下几个方面:

(1) 在医学方面,神经网络可用来对一些复杂的生物学信号进行检测与自动分析,对医学图像进行识别与处理。同时可建立庞大的医学知识库,将专家的先决知识经验储于其中,并基于此可针对临床问题进行高效的逻辑归纳与诊断,该知识库可称为医学专家系统。

(2) 在经济学领域,可针对造成市场供需关系变化的多种因素系统化分析,评估商品的价格变动,做出市场价格的预测。还可以利用神经网络的预测思维对市场风险进行评估。

(3) 在交通运输领域，由于交通运输问题的特点是具有高度非线性，需要处理大规模的复杂数据，而神经网络自身的优良特性能很好地针对此类相关问题有效处理。神经网络在此领域涉及的范围极为广泛，如对交通驾驶员的操作模拟、交通模式分析、交通路线规划、车辆流量预测等方向都卓有成效。

(4) 在信息领域，神经网络的应用主要在两个方面，其一是对于实际信息的处理，其二是模式识别。现代世界的各类信息相当复杂，而神经网络具有对人的思维、行为方式进行模拟的能力，因此可避免传统方法耗时耗力的缺点，针对问题进行自动诊断与解集寻优。

(5) 在国防安全领域，神经网络可进行人脸识别，对各类军用雷达、传感器的图像信号进行处理，在目标物体的跟踪、军用武器的操控等方面也具有极大的优势。

3.2 基于遗传算法与 BP 神经网络结合的 PID 控制

3.2.1 PIDNN 控制器及神经网络结构

图 3-1 为基于 BP 网络的 PID 控制系统原理图，其中 r 是控制器设定的目标温度， y 代表被控系统反馈的温度值， u 表示 PID 神经网络控制器的输出电压（即加热器的电压）。PID 神经网络控制系统的目标机理是不停地最小化系统设定的目标值与系统实际输出值之间的误差。




图 3-1 基于 BP 网络的 PID 控制系统原理图

Fig 3-1 Schematic diagram of PID control system based on BP network

图 3-2 为 PID 神经网络结构图，控制器采取三层网络结构，包括输入层、隐层与输出层。它将能够对被控对象进行闭环控制的 PID 控制器与具有良好非线性、自学习、自适应特性且能对比例、积分、微分参数进行在线调整的神经网络二者之间的优点相

结合。




图 3-2 PID 神经网络结构图

Fig 3-2 PID neural network structure diagram

神经网络输入层两个神经元的输入量可表示为：

$$x_1(k) = r(k) \quad (3-1)$$

$$x_2(k) = y(k) \quad (3-2)$$

上述公式中， k 是温控系统调控的离散采样时间， $r(k)$ 表示设定的目标温度， $y(k)$ 则代表被控系统实际的输出温度。

神经网络的隐层分别为 P(比例单元)、I(积分单元)、D(微分单元)三个神经元，P 节点的输出量即为其输入量。I 神经元会进行输出反馈，对该节点输出量 u_2 延迟一个单位的采样周期，接着再反馈至输入量 n_2 。D 神经元执行的是输入反馈，与 I 节点不同的是，它进行延迟单位采样周期此行为作用的对象是输入量 n_3 ，紧接着再负反馈给输入。图 3-2 中 Z^{-1} 表示的是 I、D 节点中的单位延迟算子，即单位采样周期的延迟量。神经网络隐层的输出量可以根据隐层各神经元的输入量与前一个周期的输出量以如下公式表示：

$$u_1(k) = n_1(k) \quad (3-3)$$

$$u_2(k) = n_2(k) + u_2(k-1) \quad (3-4)$$

$$u_3(k) = n_3(k) - n_3(k-1) \quad (3-5)$$

神经网络相邻层之间的节点互相连接构成连接权值，本文使用 w_{ij} 表示输入层与隐层之间各节点的连接权值，以 w_o 来代表隐层与输出层间各节点的连接权值。隐层

的输入量为:

$$n_i(k) = \sum_{j=1}^2 w_{ij} x_j(k), i=1,2,3 \quad (3-6)$$

神经网络输出层的输入量即为各隐层神经元的输出量,输出层的输出量即对应的是温控系统接受到温度反馈输出的电压(加热器的电压),可用以下公式表示:

$$u(k) = \sum_{i=1}^3 w_i u_i(k) \quad (3-7)$$

3.2.2 遗传算法初始化权值

在PID神经网络实际执行调控前,会使用遗传算法^[58]进行预先训练,从而缩小权值的分布范围对其进行优化,得到一组能使系统在调控开始阶段便能保持稳定的连接权值,随后再利用神经网络的自适应调整特性进一步精确求解,从而避免神经网络调控产生的值陷入局部极小现象,以使控制系统能够稳定而迅速的收敛。

在使用遗传算法对权值进行优化时,首先设定遗传算法的编码形式为实数编码,以满足随后进行的神经网络自适应调整权值的阶段对参数较高精度的需求。再在第一代随机生成50组连接权值作为初始种群,同时设定种群的规模为50。

种群向下进行遗传进化的过程中,只有那些能够让控制系统保持稳定的个体会得以保留,种群会因淘汰一部分个体而使规模减小,上一代种群中的个体参数集会通过某特定的概率进行交叉与变异以进化生成新的参数集从而让种群达到原设定的规模。在种群进化了50代时,结束遗传算法的进程,得到的预训练结果即为问题的最优解,也就是最优的一组连接权值集合。遗传算法执行的关键因素是适应度函数,只有满足适应度函数的个体或参数才能向下一代遗传进化,否则将会被淘汰。本章节选取控制系统的误差与惩罚项二者之和作为适应度函数,可用以下公式表示,该式中 N 表示采样的样本总数, $e(k)$ 所代表的是控制器的误差,误差的后一项即为系统的惩罚项,其中 λ 代指调控过程中超调行为的惩罚因子。

$$F = \sum_{k=1}^N (|e(k)| + \lambda |y(k) - y(k-1)|) \quad (3-8)$$

$$\lambda = \begin{cases} 0, & \text{if } y(k) \geq y(k-1) \\ \epsilon, & \text{otherwise} \end{cases} \quad (3-9)$$

3.2.3 反向传播自适应调整权值

在控制系统进行调控时,系统会利用神经网络的反向传播算法对连接权值进行自适应修正调整从而实现在线训练。权值调整过程中,我们首先设定一个性能指标函数:

$$J(k) = \frac{1}{2} e^2(k) = \frac{1}{2} (r(k) - y(k))^2 \quad (3-10)$$

随后通过反向传播算法,沿着该性能指标函数的下降梯度对神经网络的连接权值

进行修正。反向传播算法主要包含两个连续的步骤，分别是对输出层权值的调整与对输入层权值的调整。第一步先调整输出层的权重： ω_1 ， ω_2 与 ω_3 。根据计算的链式法则，性能指标函数对输出层连接权重的关系梯度可用以下公式表示：

$$\begin{aligned}\frac{\partial J(k)}{\partial w_i(k)} &= \frac{\partial J(k)}{\partial y(k)} \cdot \frac{\partial y(k)}{\partial u(k)} \cdot \frac{\partial u(k)}{\partial w_i(k)} = -e(k) \cdot \frac{\partial y(k)}{\partial u(k)} \cdot u_i(k) \\ &\approx -e(k)u_i(k) \operatorname{sgn}\left(\frac{\Delta y(k)}{\Delta u(k)}\right), i=1,2,3\end{aligned}\quad (3-11)$$

在此公式中，

$$\Delta y(k) = y(k) - y(k-1) \quad (3-12)$$

$$\Delta u(k) = u(k) - u(k-1) \quad (3-13)$$

$$\operatorname{sgn}(x) = \begin{cases} 1, & \text{if } x > 0 \\ 0, & \text{if } x = 0 \\ -1, & \text{if } x < 0 \end{cases} \quad (3-14)$$

根据输出层权值的调整梯度，可得到修正后的权值为：

$$\begin{aligned}w_i(k) &= w_i(k-1) \eta_o \frac{\partial J(k)}{\partial w_i(k)} \\ &= w_i(k-1) + \eta_o e(k) u_i(k) \operatorname{sgn}\left(\frac{\Delta y(k)}{\Delta u(k)}\right), i=1,2,3\end{aligned}\quad (3-15)$$

该式中， η_o 为输出层权值的学习率。

其次，进行反向传播算法的第二个步骤，即调整神经网络隐层的连接权值，此过程与第一步很类似，在此步骤进行时，第一步完成后已经更新修正的输出层连接权值会被作为影响此步骤的参数因子，调整隐层权值的过程可用以下公式进行表示，其中公式（3-16）为隐层连接权值梯度的主要参数，公式（3-17）则为根据下降梯度调整之后的隐层权值量：

$$\begin{aligned}\frac{\partial J(k)}{\partial w_{ij}(k)} &= \frac{\partial J(k)}{\partial y(k)} \cdot \frac{\partial y(k)}{\partial u(k)} \cdot \frac{\partial u(k)}{\partial u_i(k)} \cdot \frac{\partial u_i(k)}{\partial n_i(k)} \cdot \frac{\partial n_i(k)}{\partial w_{ij}(k)} \\ &= -e(k) \cdot \frac{\partial y(k)}{\partial u(k)} \cdot w_i(k) \frac{\partial u_i(k)}{\partial n_i(k)} \cdot x_j(k) \\ &\approx -e(k)w_i(k)x_j(k) \operatorname{sgn}\left(\frac{\Delta y(k)}{\Delta u(k)}\right) \operatorname{sgn}\left(\frac{\Delta u_i(k)}{\Delta n_i(k)}\right), i=1,2,3, j=1,2s\end{aligned}\quad (3-16)$$

$$\begin{aligned}w_{ij}(k) &= w_{ij}(k-1) - \eta_h \frac{\partial J(k)}{\partial w_{ij}(k)} \\ &= w_{ij}(k-1) + \eta_h e(k) w_i(k) x_j(k) \operatorname{sgn}\left(\frac{\Delta y(k)}{\Delta u(k)}\right) \operatorname{sgn}\left(\frac{\Delta u_i(k)}{\Delta n_i(k)}\right), i=1,2,3, j=1,2s\end{aligned}\quad (3-17)$$

类似地， η_h 也是用来表示调整隐层连接权值的学习速率。在神经网络自适应调

整算法中，权值是调整过程中极为关键的参数，因此，必须对连接权值训练的学习率进行合理设定才可确保代价函数能够进行快速收敛。本章综合考虑了学习速率对代价函数收敛特性的影响，故将隐层权值的学习率与输出层权值的学习率设定为相同值。

神经网络的自适应学习过程中，代价函数的变化量可用以下公式表示：

$$\begin{aligned}\Delta J(k) &= J(k+1) - J(k) = \frac{1}{2}(e^2(k+1) - e^2(k)) \\ &= \frac{1}{2}(e(k+1) + e(k))(e(k+1) - e(k)) = \frac{1}{2}(2e(k) + \Delta e(k))\Delta e(k) \\ &= \Delta e(k)(e(k) + \frac{1}{2}e(k))\end{aligned}\quad (3-18)$$

在某一时刻，将隐层权重的学习率与输出层权重的学习率设定为相同值，则权重的调整规则表达式为：

$$w_u(k) = w_u(k-1) - \eta \frac{\partial J(k)}{\partial w_u(k)} = w_u(k-1) + \eta e(k) \frac{\partial y(k)}{\partial u(k)} \frac{\partial u_i(k)}{\partial w_u(k)} s \quad (3-19)$$

误差的变化量可表示为：

$$\Delta e(k) = \left(\frac{\partial e(k)}{\partial w_u(k)}\right)^T \Delta w_u(k) = -\left(\frac{\partial y(k)}{\partial u(k)} \frac{\partial u(k)}{\partial w_u(k)}\right)^T \eta e(k) \frac{\partial y(k)}{\partial u(k)} \frac{\partial u(k)}{\partial w_u(k)} \quad (3-20)$$

综合以上公式，可将代价函数的变化量表示为：

$$\begin{aligned}\Delta J(k) &= \Delta e(k)(e(k) + \frac{1}{2}e(k)) \\ &= \left(\frac{\partial e(k)}{\partial w_u(k)}\right)^T \eta e(k) \frac{\partial y(k)}{\partial u(k)} \frac{\partial u(k)}{\partial w_u(k)} \left[e(k) + \frac{1}{2}\left(\frac{\partial e(k)}{\partial w_u(k)}\right)^T \eta e(k) \frac{\partial y(k)}{\partial u(k)} \frac{\partial u(k)}{\partial w_u(k)}\right] \\ &= -\eta e^2(k) \left(\frac{\partial y(k)}{\partial u(k)}\right)^2 \left\|\frac{\partial u(k)}{\partial w_u(k)}\right\|^2 + \frac{1}{2}\eta^2 e^2(k) \left(\frac{\partial y(k)}{\partial u(k)}\right)^4 \left\|\frac{\partial u(k)}{\partial w_u(k)}\right\|^4 \\ &= -\frac{\eta}{2} e^2(k) \left(\frac{\partial y(k)}{\partial u(k)}\right)^2 \left\|\frac{\partial u(k)}{\partial w_u(k)}\right\|^2 \left[2 - \eta \left(\frac{\partial y(k)}{\partial u(k)}\right)^2 \left\|\frac{\partial u(k)}{\partial w_u(k)}\right\|^2\right]\end{aligned}\quad (3-21)$$

本实验中，神经网络趋向于收敛的条件为代价函数 $\Delta J(k)$ 的值小于或等于零，由此公式可知，当学习率的取值范围为 $0 < \eta \leq \frac{2}{\left(\frac{\partial y(k)}{\partial u(k)}\right)^2 \left\|\frac{\partial u(k)}{\partial w_u(k)}\right\|^2} s$ 时能保证神经网络的收敛性。

反向传播算法实际调整时，本研究首先在遗传算法已确定了合适的初始权值的条件下，选定不同的权值学习率代入神经网络的执行过程，其次再从中挑选出能够让神经网络快速收敛的学习率，这样就能确定满足调整条件的最理想的权值学习率。

从上述章节可得，利用遗传算法对神经网络控制进行优化的思想为：首先随机初始化神经网络的权值并运用遗传算法对其优化，从而将它们缩减至一个较小的范围。第二步再利用 PID 神经网络与其反向传播算法对控制系统执行更进一步的精确求解。这种将两类算法结合的思想能够充分发挥各自算法的优势，以防止神经网络陷入局部

极小值现象，从而实现算法的迅速收敛。

3.3 改进 BP 算法优化的 PIDNN

由于基于传统 BP 算法的神经网络属于前馈型网络，该网络是将诸多简单神经元通过互联结合的方式让网络本身拥有强大的非线性映射能力，然而却难以对控制系统进行即时反馈，所以从严格意义以上来看，它由于理论上的完整性尽管能较好地被运用于实际工农业控制领域中，但是却也存在着一些缺陷，如：

(1) 给定初始连接权值使用神经网络进行调控时，可能存在较多的局部最小点，造成算法的执行陷入局部最小的现象。在某些特殊情况下，单个局部极小点极有可能会造成训练结果与调控目标相差甚远，由此造成学习完全失败。

(2) 当神经网络内部规模增大时，不仅进行学习的计算量会大幅增大，而且网络的学习步数也会相应增加，此种现象会使算法执行结果的收敛速度变得极为缓慢。

(3) 由于对于学习率的选取缺乏理论指导，相当依赖于实际调控的试验，而不恰当的学习率会导致训练时间变得极为漫长，甚至，会导致训练无法正常进行。例如选定一个较大的学习率用于传统 BP 神经网络的训练过程时，由于此过程中学习率始终不会发生变化，则权值的调整量会因过大而引发在网络在系统误差最小处发生振荡，使算法的收敛缓慢甚至无法收敛。

为了改良 BP 算法的缺点从而改善神经网络的性能，本章节利用改进 BP 算法结合 PIDNN 的调控方式对其进行优化。由于标准 BP 算法的作用机理是修正性能指标函数与连接权值的梯度，故而改进算法多是基于 BP 算法中梯度下降的特征，本研究选取的是添加动量项的方法。

动量项具有记忆控制系统上一时刻连接权重变化方向的作用，由此我们便能够通过选取较大的学习率系数来加快神经网络学习训练的速度，进而提高调控效率。动量项还具有“惯性效应”，可对系统因干扰等因素产生的振荡现象加以抑制，使其通过缓冲作用而趋向于平滑。除此之外，添加动量项对控制器脱离平坦区域也具有良好的促进作用。

神经网络进行训练时，倘若误差曲面开始趋向于平坦区域，误差的变化幅度会相当微小，与此同时，对权值的调整也会相应地缩减至一个较小的范围内，这也意味着上一时刻的权值调整量开始接近于当前时刻的调整值，即

$$\Delta w(n-1) \approx \Delta w(n) \quad (3-22)$$

传统 BP 算法的连接权值的修正公式为：

$$\Delta w(n) = -\eta \frac{\partial E}{\partial w} \quad (3-23)$$

在添加了动量项后，连接权值的修正公式变化为：

$$\Delta w(n) = -\eta \frac{\partial E}{\partial w} + \alpha \Delta w(n-1) \quad (3-24)$$

将上述公式代入此公式中，可得到：

$$\Delta w(n) = -\frac{\eta}{1-\alpha} \frac{\partial E}{\partial w} \quad (3-25)$$

由此可知，添加了动量项后，连接权修正式中的系数由 $-\eta$ 改变为 $-\frac{\eta}{1-\alpha}$ ，显然 $|\frac{\eta}{1-\alpha}| > |-\eta|$ ，从而促使神经网络的调控能更迅速地脱离饱和区域，加快收敛的速度。

分别将 GA-PIDNN 算法与经改进 BP 算法优化了的 GA-MPIDNN 算法引入上述温室大棚模型的 Python 数字模拟仿真环境，设定目标温度为 35 度，初始温度为 5 度，采样时间为 300 秒，采样时间间隔为 1s，动量因子为 0.3，比较跟踪性能差异。此两种算法的系统响应曲线分别如图 3-3 与图 3-4 所示：




图 3-3 GA-PIDNN 与 GA-MPIDNN 温控闭环响应曲线

Fig 3-3 GA-PIDNN and GA-MPIDNN temperature control closed-loop response curve

表 3-1 跟踪性能对照表

Tab 3-1 Trace the performance comparison table

调控方法	超调量 (°C)	调控时间 (至稳态) (s)
GA-PIDNN	0.25	68
GA-MPIDNN	0.05	60

此两种方法调控的主要跟踪性能对照表（超调量与到达稳态的时间）如表 3-1 所示。从两种算法的跟踪性能曲线显而易见可看出，使用改进 BP 算法优化后曲线振荡程度明显减小，曲线趋于平滑，超调量明显降低。再综合实验的性能结果参数，可知使用 GA-PIDNN 调控到达稳态的时间约为 68 秒，超调量为 0.25；而经过改进的 GA-MPIDNN 约为 60 秒，超调量为 0.05。所以可以确定，添加动量项改进后在一定程度上能有效缓解了网络训练时系统的振荡，起到了缓冲平滑的作用，同时减少了在平坦区的停留时间，加快了系统的收敛速度。

3.4 基于 GA-MPIDNN 的温室大棚温度仿真控制

3.4.1 控制器结构与调控流程

使用遗传算法（GA）对随机权值集合优化后得到最优初始权值，再与改进后的 PID 神经网络相结合构成新的基于遗传算法的 PID 神经网络（GA-MPIDNN）控制器，该控制器的具体结构如图 3-5 所示，其中 r 是控制器设定的目标温度， y 代表被控系统反馈的温度值， u 表示 PID 神经网络控制器的输出电压（即加热器的电压）。




图 3-5 GA-MPIDNN 控制器结构图

Fig 3-5 GA-MPIDNN controller structure diagram

利用 GA-MPIDNN 进行温室大棚温度的智能化调控时，在控制周期内，首先通过被控对象（温室大棚环境）当前的温度与设定的目标温度通过 GA-MPIDNN 算法进行处理得到控制器下一时间步所需的电压，再将该电压施加于加热器，加热器释放热量改变温室大棚的温度，以此方式逐步操作不断迭代至温室大棚达到设定的目标温度，从而构成温室大棚温度智能化控制的闭环调节。具体的实际仿真调控步骤如下：

- (1) 初始化被控对象（温室大棚）的当前温度。
- (2) 设定温室大棚需要达到的目标温度。
- (3) 对神经网络进行预训练并利用遗传算法得到最优的初始化连接权值。
- (4) 选定合适的神经网络各层间连接权值的学习率。
- (5) 读出当下的温室大棚系统温度，记为 $y(k)$ 。
- (6) 通过改进的 PID 神经网络计算出控制信号（电压） $u(k)$ 。
- (7) 网络中改进的反向传播算法以控制系统的误差（温室大棚目标温度与当前温度的差值）自适应地调整连接权值。
- (8) 将控制信号 $u(k)$ 作为电压输入至本研究中仿真环境的温室大棚温控加热器模型。
- (9) 温室大棚加热器模型输出当前温度（温室大棚温度）。
- (10) 将参数更新返回步骤 5，直至实际温室大棚温度达到设定的目标温度。

3.4.2 仿真结果

将控制对象引入以上章节中构建的与 ZN 法、遗传算法相同的 Python 数字模拟仿真环境中，控制器选定 GA-MPIDNN 算法。设定调控的目标温度为 37 度，初始温度为 5 度，给定权值范围为 -1 至 1，遗传算法种群规模与最大进化代数均设为 50，交叉率、变异率取 0.8，利用遗传算法得到最优的初始连接权值集合，设定隐层、输出层的权值学习率都为 -1，动量因子为 0.3，采样时间间隔为 1s，采样总时间为 600s，使用 GA-MPIDNN 进行智能化温室大棚温度仿真调控。遗传算法优化初始权值时权值的适应度分数迭代过程如图 3-6 所示，系统的闭环响应曲线如图 3-7 所示，表 3-2 表示此方法的具体仿真调控结果。




图 3-6 GA 优化权值阶段适应度分数的迭代

Fig 3-6 Iteration of fitness score in GA optimization weight stage

由图 3-6 可看出，遗传算法优化初始权值阶段的适应度分数在第 1 代至第 5 代迅速下降，表明遗传算法具有较好的收敛性，在随后阶段，适应度分数值依旧保持缓慢下降直至在最终代得到一个最小值 0.812，也意味着遗传在进化终止时得到了预设问题的近似最优解，即权值的最优集合。




图 3-7 系统闭环响应曲线

Fig 3-7 System closed-loop response curve

表 3-2 GA-MPIDNN 仿真调控结果表

Tab 3-2 GA-MPIDNN simulation control results table

调控方法	超调量 (°C)	平均稳态误差 (°C)	最大稳态误差 (°C)	调控时间(s)
GA-MPIDNN	0.01	0.00	0.00	68

综合系统的闭环响应曲线图与实验运行的结果可知，使用 GA-MPIDNN 在给定的理想环境下，温度响应曲线极为平滑，在系统误差较小时能快速脱离平坦区，迅速收敛，控制系统的超调量趋近于 0，调控过程达到预设目标温度所需的时间较短，且无振荡现象产生，平均稳态误差与最大稳态误差均为 0，在时间为第 68s 时便到达稳态。

3.5 实验结果对比分析

将遗传算法结合改进的 PID 神经网络 (GA-MPIDNN) 此算法对温室大棚温度的仿真调控效果,与上述章节采用的 ZN 法与遗传算法整定 PID 控制器参数从而实现温室大棚温度调控效果进行对比,得到表 3-3。从此表中可明显看出:比起其他两种算法,使用 GA-MPIDNN 的调控方式超调量更小,平均稳态误差为 0,稳态性更好,调控过程中几乎无振荡,控制系统的响应速度极快,比起使用 ZN 法调控的 156 秒,遗传算法调控的 96 秒,本方法在第 68 秒便能达到系统的稳态,温室大棚到达设定的目标温度所需的时间再次显而易见的减少!由此,我们能得到的结论是:在给定的一个环境下,比起另外两种方法,使用基于遗传算法的改进 PID 神经网络这种智能策略凭借其强大的自适应、自调整等优良特性成功实现了对于温室大棚温度高效率、高精度且高度稳定的调控。此方法不仅合理地降低了超调量、有效缩短了为达到目标温度所需的时间,而且在加快系统的响应速度、提高系统稳态性等诸多方面都具备更大的优势。

表 3-3 此环境下不同方法仿真效果比较表

Tab 3-3 Comparison table of simulation results of different methods in this environment

调控方法	超调量	平均稳态误差	最大稳态误差	调控时间(s)
ZN 法	12.85	1.68e-10	2.5e-09	156
(GA)遗传算法	5.19	3.72e-11	1.1e-10	96
GA-MPIDNN	0.01	0.00	0.00	68

3.6 小结

本章首先从基本理论和应用领域两个方面对人工神经网络进行了简要介绍,阐述了神经网络的一些优良特性,如强大的非线性逼近能力、并发处理复杂问题与数据的能力、自适应学习调整的能力、快速收敛、能够实现高效而稳定的调控能力等。其次介绍了基于遗传算法与 BP 神经网络结合的 PID 控制这种调控方法,其中依次对 PIDNN 控制器及神经网络结构、遗传算法初始化最优权值、反向传播算法调整权值做了较为详细的论述。接着通过添加动量项的方式改进 BP 算法从而对 GA-PIDNN 算法进一步优化。最后使用 GA-MPIDNN 算法进行温室大棚温度的仿真控制,将其控制效果与使用 ZN 法、遗传算法进行对比分析,得到该方法在超调量、调控速度、稳态误差、稳定性等多个方面都具有更为明显的优势的结论。

4 小型温室大棚温度控制系统的构建

4.1 系统整体设计

通过上述章节中多种算法实行温室大棚温控的仿真结果可以得知，使用遗传算法与改进 PID 神经网络相结合的算法（GA-MPIDNN）进行温室大棚的智能化温度控制具有更优良的效果。由此，我们可以将此算法引入现实环境，进行实际温室大棚温度控制系统的设计与调试。

为了较好地保证温室大棚温度的调控精度、可靠性、稳定性等，我们要对系统的硬件进行合理选择，首先要基于满足控制系统性能的前提，综合考虑实际因素（如软硬件、连接线路成本），挑选出具有较高性价比的软硬件组合对温室大棚智能化温控系统进行组建。

本温室大棚控制系统包含的组成成分主要为：上位机（PC 计算机）、下位机、串口通信的连接线路、温湿度传感装置、电源、控制继电器以及执行机构（电热丝、加热风扇装置）等^[59]，系统的被控对象为一个小型温室大棚。本系统主要的控制原理可简要概括为：置于温室大棚中的温度传感器获取到温度数据之后通过 STM32F103 单片机以串口通信的方式传输至上位机（PC 计算机）中，计算机得到实时温度数据后将其显示出来，再将数据提交至 GA-MPIDNN（Python 编写）算法，运算得到系统的控制信号——电压，随后上位机又以串口通信的方式将控制命令给到 STM32F103 单片机，再传达至于温室大棚中的执行装置加热以实现控温的效果。该系统的整体结构框图可用图 4-1 表示：




图 4-1 系统结构图

Fig 4-1 System structure diagram

4.2 系统上位机

在本研究搭建的小型温室大棚温度控制系统中，上位机是整个系统的上层管理部分，其功能主要可概括为两个方面：其一是接收到由温度传感器测量传至单片机再通过串口通信传输到 PC 机的温度数据并将此数据实时显示，绘出温度的实时变化曲线；其二是设定目标温度，基于设定的目标温度和获取到的温度通过上述章节中优良的智能控制算法（即 GA-MPIDNN）计算出可用于下层硬件调控的控制电压的数据信号再通过串口向单片机传递。

本系统中上位机主要使用 Python 作为核心处理工具，在其中编写智能处理算法（GA-MPIDNN），本系统中有两个主要界面：一个是登陆界面，一个是控制主界面。分别如图 4-2、图 4-3 所示。调控人员在登陆界面上输入正确的用户名与密码通过校验后便可跳转至控制主界面。控制主界面中能对温室大棚期望的目标温度、串口通信线路对应的串口号、波特率等参数进行设定，设定完毕后按下“调控”按钮，系统便可利用串口通信的方式获取到温室大棚中的传感器测得的温度数据，将其分析保存并以变化曲线的方式实时显示于主控制界面。在此过程中，当 PC 机接收到的温度数据小于或高于设定的目标温度参数，上位机会通过 Python 中编写的 GA-MPIDNN 算法计算输出对应的控制量数据，再将控制命令传送到单片机，单片机再驱动下位机的各执行机构进行温度的精确调节^[60]。



图 4-2 系统登录界面

Fig 4-2 System login interface

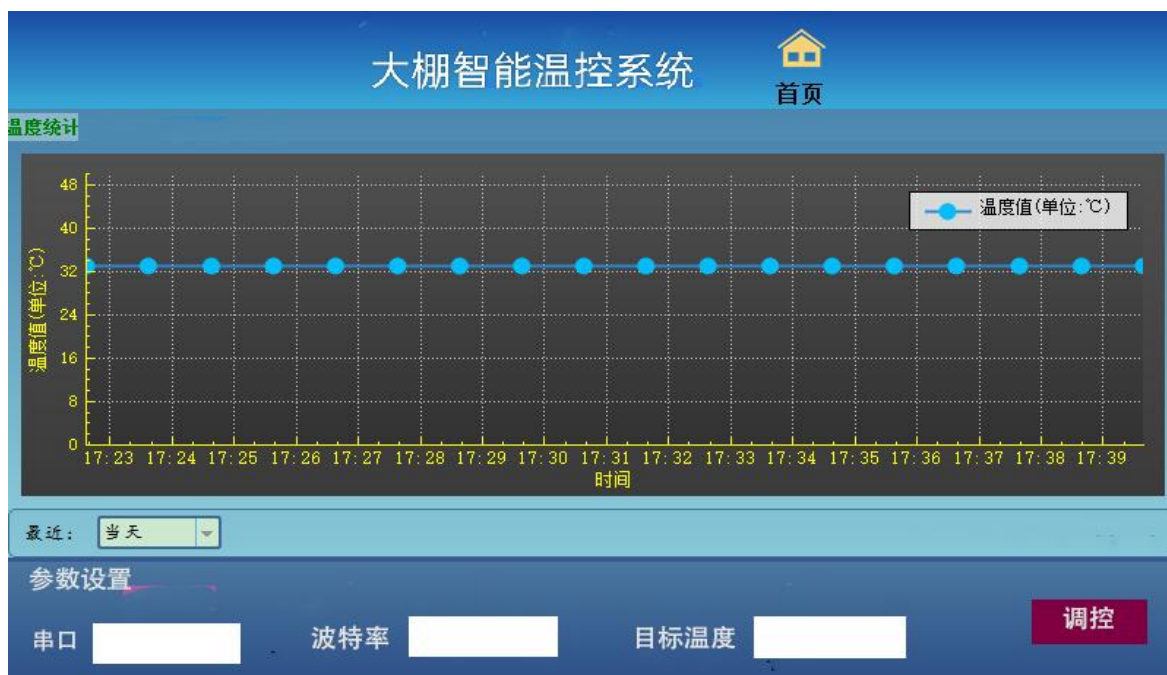


图 4-3 系统控制主界面

Fig 4-3 System control main interface

本系统上位机中 PC 计算机与单片机之间是以串口通信的方式来实现数据信号的传输通讯的，串口通信是当下工业领域应用于 PC 串口与外接设备之间的一种操作简单、使用广泛的数据通信方法。串口，即 COM 接口，是一种成本较低、线路简单的计算机内部通用设备通信协议，一般选取 RS232 接口标准就能够实现数据的稳定传输。本研究中控系统的数据通讯是基于 Python 的串口通信，在控制程序中先设定能够匹配 CH340（USB 转串口芯片）的参数，编写接收或传送数据至此硬件的逻辑，其次在 USB 接口中使用带有 CH340 硬件的串口通讯线将 PC 机与单片机连接，数据可以基于此线路通过串口助手与 CH340 硬件驱动程序在 PC 机与单片机之间接收与传送，从而较简易地实现 PC 与上位机的通信。此过程中的 USB-CH340 串口通讯线如图 4-4 所示，线路工作时 PC 机上的串口助手如图 4-5 所示。



图 4-4 USB-CH340 串口通讯线

Fig 4-4 USB-CH340 serial port communication cable



图 4-5 串口助手图

Fig 4.5 Serial Assistant diagram

4.3 系统下位机

本研究设计的小型温室大棚温度控制系统中，系统下位机以单片机为温度监测与调控的核心处理工具，通过温度传感器对温室大棚中环境中的温度进行测量采集并将其转换成高、低电平信号便于单片机接收，接着单片机再将此信号向上位机发送，上位机接收到信号后对其执行智能策略处理计算出控制信号，再把控制信号反馈到单片机，单片机基于此控制命令驱动加热装置运行从而实现系统温度的智能化调节。

本系统中下位机选定的单片机为 STM32F103C8T6（如图 4-6 所示），该单片机开发板的主要技术参数如表 4-1 所示。比起其他种类的单片机，STM32F103C8T6 具有相当多的优势，其功耗成本较低、价格低廉、LQFP48 封装的体积较小且性能颇为强大^[61]。STM32F103C8T6 工控板^[62]内部含有较多的电路模块，其中包括 CAN 接口电路、RS-485 接口电路等，近乎能满足全部的硬件电路需求。不仅如此，使用该开发板对倾向于掌握 STM32 相关知识的人而言有很强的实用性与很大的学习意义，且该开发板的实惠性令系统的设计成本极低^[63]。对于本研究中的小型温室大棚温度控制系统，STM32F103C8T6 凭借其优良特性能很好的适配其中。




图 4-6 STM32F103C8T6 核心板

Fig 4-6 STM32F103C8T6 core board

表 4-1 STM32F103C8T6 核心板主要参数表

Tab 4-1 Main parameters of STM32F103C8T6 core board

核心板部件	主要参数
内核	ARM Cortex-M3 内核
存储器	64K 字节 Flash 存储器，20K 字节 SRAM
I/O 口	37 个通用可编程 I/O 口
ADC	2 个 12 位的 ADC, ADC1 与 ADC2 都包含 16 个外部通道，每个通道的模数转换可以进行单次或扫描转换
通信接口	含有 3 个 USART 接口，1 个 CAN 接口
DMA	7 通道 DMA 控制器
工作电压	2.0-3.6V 之间

系统下位机运转时的温度信息采集模块，即单片机接收温度传感器于温室大棚中测量的温度此部分中，本系统选取的是 AHT10 温湿度传感器，如图 4-7 所示。该传感器的温度测量范围在-40℃到 85℃之间，精度为±0.5℃，具有高精度、可进行完全校准、可靠性极高、稳定性卓越、性价比极高等诸多优良特性，因此在工业、农业工程领域被广泛运用，传感器性能参数可如表 4-2 所示。




图 4-7 传感器实物图

Fig 4-7 Physical sensor drawing

表 4-2 传感器性能参数表

Tab 4-2 Sensor performance parameter table

传感器性能指标	主要参数
供电电压	DC:2.3-3.3V
测量范围（湿度）	0-99%RH
测量范围（温度）	-40 到+85℃
湿度精度	±3%RH（25℃）
温度精度	±0.5℃
分辨率	温度：0.1℃
	湿度：0.1%RH
输出信号	IIC 信号

系统下位机对温室大棚温度的实际调控过程具体为，单片机接收到 PC 端经过智能算法运算后输出的控制信号（电压），将该信号传送至置于温室大棚中的执行机构进而使其运转，从而实现系统对于实际温室大棚环境中温度实时、动态、智能、精确的调节。此过程中选取 PTC 直流风扇（24V 400W）作为执行装置，其实物图如图 4-8 所示。



图 4-8 PTC 直流风扇实物图

Fig 4-8 PTC DC fan diagram

图 4-9 表示的是系统下位机的线路连接。




图 4-9 下位机的连接

Fig 4-9 Connection of lower computer

4.4 温度调控的实际测试

将系统上位机、下位机整体成功连接后，把直流风扇放置于外接的温室大棚内，开启电源，在 PC 端 Python 主程序内设定好与串口匹配的参数（串口设为“com10”，bps 设为 115200），初始环境温度为 21.4 度，设定控制系统想要达到的目标温度为 27 度，采样的时间间隔为 1 秒，启动主程序进行温控的实际测试。可观测到小型温室大棚温度控制系统开始进行调控，系统监测到系统的温度实时变化曲线如图 4-11 所示。




图 4-11 控制系统实际温度变化曲线图

Fig 4-11 Actual temperature change curve of control system

此系统在实际环境下前 600 秒的周期内,进行温度智能化控制的调控效果表如表 4-3 所示。根据此表可看出,与仿真环境下的实验结果相比,由于实际环境中温室大棚外部光照、空气含氧量、风速变化、串口通信线路存在噪声等诸多因素的影响,小型温室大棚温度控制系统的超调量、平均稳态误差有小幅的增大,尽管如此,这些性能参数仍然保持处在一个较小的范围之内(超调量为 1.5,平均稳态误差为 1.33,最大稳态误差 1.50),同时综合系统的响应曲线可知,系统在调控的第 100 秒左右即开始在设定目标温度 27 度附近稳定地上下微小浮动,于是可得出结论:本实验设计搭建的系统在实际环境中成功实现了智能化温度控制且达到了较为理想的调控效果。

表 4-3 系统实际环境调控效果表

Tab 4-3 System actual environmental regulation effect table

调控方法	超调量 overshoot	平均稳态误差	最大稳态误差	调控时间(s)
GA-MPIDNN 温室大棚温控系统 (实际环境)	1.5	1.33	1.50	100

本研究设计搭建的小型温室大棚温度控制系统将遗传算法与改进的 PID 神经网络结合的智能控制策略引入实际环境，实现了温室大棚温度的自适应调控。图 4-12 展示的即为实际连接的整个系统。




图 4-12 小型温室大棚温度控制系统

Fig 4-12 Small greenhouse temperature control system

4.5 小结

本章将上部分章节中用于温室大棚温控仿真实验的效果最优的算法（GA-MPIDNN）引入实际环境中，构建一个小型温室大棚智能温度控制系统。首先对此系统的整体设计进行了介绍，其中阐述了系统上位机与下位机互联合作的整体原理并画出控制系统的整体结构图。其次介绍了系统的上位机，概括了上位机的主要功能、结构与执行原理。接着讲述了系统下位机的主要功能、工作原理以及主要的工作流程，对其中单片机对于温度传感器温度的接收、单片机对执行机构控制信号的传递两个过程做了较为详细的介绍。最后，设定好调控目标及其他调控参数，在实际环境中对此系统进行温度的监测以及控制，观测到温度的实时调控曲线。该曲线显示的实验结果证明：本系统成功实现了智能化温度控制且达到了较为理想的调控效果。

5 总结与展望

5.1 全文总结

我国是农业大国,农业是我国经济结构中极为关键的一环,农业生产效率的高低会对我国经济的发展产生重大的影响。温室大棚能为农业作物的生长提供一个极为适宜的温度环境,因此对温室大棚温度进行高精度、高效率的控制,能让农作物产出的效率得到极大的提升。本文就此提出了以 ZN 法整定 PID 控制器参数、以遗传算法整定 PID 控制器参数、将遗传算法结合改进的 PID 神经网络(GA-MPIDNN)此三种方式对大棚温度进行了仿真实验,并将收敛性最强、自适应学习特性最佳、调控效果最优的 GA-MPIDNN 算法引入实际环境中,构建了现实环境下塑料温室大棚的温度控制系统,从而实现对大棚内温度高效、迅速、稳定的智能化调控,以达到提高农作物生产效益、提升农业经济效益的目的。本论文主要完成的工作具体如下:

(1) 通过查阅大量文献,对有关温室大棚温度调控的研究背景、研究意义以及研究现状做了较为详细的阐述,同时简要介绍了本论文的研究目标与研究内容。

(2) 基于自然界中的热传递平衡定律,推导出大棚温控模型的传递函数形式。对一个塑料温室大棚温箱注入阶跃电压信号,通过温度的响应曲线使用两点拟合算法计算出模型的实际参数值,从而获得具体的大棚温控动态数学模型。

(3) 对温室大棚温度的智能化调控策略进行了深度探究,首先介绍了 PID 控制器的基本原理、PID 参数整定的常用方法以及 PID 控制的评价指标;其次针对非线性、大惯性、大时滞的温室大棚环境,分别使用 ZN 法整定 PID 参数、遗传算法整定 PID 参数的方法进而对温度实施仿真调控,结果表明:与传统的 ZN 法相比,使用遗传算法整定 PID 参数进行大棚温度控制,凭借遗传算法良好的自适应寻优特性,使调控过程中的超调量合理降低,振荡程度适当减小,系统响应速度加快,呈现出更优异的动态性能。

(4) 将具有良好自学习、自调整特性的神经网络引入 PID 控制器 (PIDNN),结合遗传算法初始化最优权值,在反向传播运算中通过添加动量项的方式对 BP 算法进行改进,以构成收敛性更强、自适应特性更佳的 GA-MPIDNN 控制器,再进行大棚温度的仿真调控。分析此方法的系统响应曲线,将其调控效果与上述另外两种方法进行对比,最终得出结论:使用 GA-MPIDNN 这种智能策略,凭借其强大的自适应、自调整特性成功实现了对于大棚温度高效率、高精度且高度稳定的调控,相比于 ZN 法与遗传算法,此方法不仅大幅降低了超调量、有效缩短了为达到目标温度所需的时间,而且在加快系统的响应速度、提高系统稳态性、抑制控制系统的振荡程度等诸多方面都具备更大的优势。

(5) 搭建基于 GA-MPIDNN 的塑料温室大棚智能化温控系统,完成系统的上下

位机设计与实现。设定调控的目标温度，进行现实环境下此系统温度调控的测试，测试结果验证了 GA-MPIDNN 算法在实际温控过程中动态性能的优越性。

5.2 展望

温室大棚温度的智能化调控是一项综合了现代化多领域前沿技术的探究，随着科学技术日新月异的发展与进步，有关于温室大棚温度的智能调控策略也在不断的更新与优化，温室大棚温度的控制系统也在不停的被开发与改进。本文中关于温室大棚温控的研究设计因受限于时间、软硬件条件等诸多因素的影响，有较多的工作等待未来更进一步的完善，主要在如下几个方面：

（1）温室大棚环境事实上内部相当复杂，除了温度之外，温室大棚还含有多种能对农作物生产造成直接影响的环境因子，这些环境因子紧密联系，相互影响。故而为了更好地促进农作物的生长，在未来的研究工作中应从实际出发，对温室大棚环境中更多的影响因子进行全面的探究，在已完成的基础上做到更深一步的扩充。

（2）本实验中系统的上位机信息传递是通过串口通信的方式实现，在未来的探究中，可以尝试利用 ZigBee 无线传输技术进行数据的采集通信，以此提高通信效率、降低现有通信线路所需的成本。

（3）可对现有的智能调控算法尝试进一步优化，考虑与模糊控制、专家系统等更多智能算法结合从而实现更好的调控。如在 PID 算法的基础上引入模糊控制理论，使控制系统在诸多调控条件不确定的情况下，依然能获取最优的调控决策与调控参数；又或者将 BP 神经网络替换为同样具有优秀特性的 RBF 神经网络，再结合遗传算法与 PID 控制器进行温室大棚温度的仿真调控，观测实验结果判断系统是否能呈现出更优越的性能。

（4）本文仅仅搭建了一个小型温室大棚智能温控系统，只是针对单个温室大棚的温度进行调控，而在实际的农业生产生活中，往往是针对数量较多的温室大棚进行远距离的集中调控，这无疑在调控软硬件环境、调控技术细节、调控参数、调控成本等多个方面具有更高的标准与要求。所以下一步的探究目标为：进行全方面综合探究与评估，在实际环境中对多个温室大棚进行集中调控并实时远程监控其温度变化，分析调控结果。

参考文献

- [1] 韦婷婷, 杨再强, 王琳, et al. 玻璃温室和塑料大棚内逐时气温模拟模型 [J]. 中国农业气象, 2018, 39(10): 644-55.
- [2] 王淦, 刘强. 温室大棚温度自动控制系统技术研究 [J]. 江西农业, 2020.
- [3] 史宇亮, 王秀峰, 魏珉, et al. 日光温室土墙体温度变化及蓄热放热特点 [J]. 农业工程学报, 2016, 32(22): 214-21.
- [4] 罗淳. 模糊自整定 PID 温室温度控制器的设计 [D]; 武汉科技大学, 2009.
- [5] 苏炜宣, 李邵, 丁小明, et al. 光温耦合对植物生长发育的影响研究进展 [J]. 中国农学通报, 2019, 35(31): 16-20.
- [6] 李振东. 蔬菜温室大棚温度控制系统 [D]; 中国海洋大学, 2010.
- [7] 朱超. 基于物联网的温室大棚远程环境监测系统 [D]; 南京信息工程大学, 2019.
- [8] 单慧勇, 张程皓, 李晨阳, et al. 温室环境自动调控系统设计 [J]. 河南农业科学, 2021, 50(8): 174.
- [9] 傅建行. 基于物联网的番茄温室环境智能调控系统设计与实现 [D]; 山东农业大学, 2020.
- [10] 陈俐均, 杜尚丰, 梁美惠, et al. 温室温度精确反馈线性化预测控制 [J]. 农机化研究, 2019, (2): 22-7.
- [11] 马娇. 试验温室温度混杂系统的建模与预测控制 [D]; 中国科学技术大学, 2018.
- [12] 栾奕, 刘昌华. 基于温度预测算法的智能粮仓温度预警系统 [J]. 计算机技术与发展, 2020, 30(09): 122-6.
- [13] 钱雅楠, 陈吉, 许癸驹. 果蔬温室温度智能自适应控制 [J]. 食品工业, 2020, 41(4): 202-4.
- [14] 皇甫立群. 基于改进 B 样条神经网络-PID 控制器的温室温度控制技术 [J]. 中国农机化学报, 2020, 41(7): 68-74.
- [15] 陈俐均, 杜尚丰, 梁美惠, et al. 温室温湿度解耦控制策略 [J]. 江苏农业科学, 2019, 1.
- [16] BENYEZZA H, BOUHEDDA M, FACI N, et al. Greenhouse Monitoring and Fuzzy Control System based on WSN and IoT; proceedings of the 2019 International Conference on Applied Automation and Industrial Diagnostics (ICAAID), F, 2019 [C]. IEEE.
- [17] BENNIS N, DUPLAIX J, ENÉA G, et al. Greenhouse climate modelling and robust control [J]. Computers and electronics in agriculture, 2008, 61(2): 96-107.
- [18] ZHANG W, CAO X, YAO Y, et al. Robust Model-based Reinforcement Learning for Autonomous Greenhouse Control; proceedings of the Asian Conference on Machine Learning, F, 2021 [C]. PMLR.
- [19] JIN C, MAO H, CHEN Y, et al. Engineering-oriented dynamic optimal control of a greenhouse

environment using an improved genetic algorithm with engineering constraint rules [J].
Computers and Electronics in Agriculture, 2020, 177: 105698.

- [20] BALTIERI M, BUCKLEY C L. PID control as a process of active inference with linear generative models [J]. Entropy, 2019, 21(3): 257.
- [21] SIVADASAN J, WILLJUICE IRUTHAYARAJAN M. Tuning of nonlinear PID controller for TRMS using evolutionary computation methods [J]. Tehnički vjesnik, 2018, 25(Supplement 1): 105-11.
- [22] ARRUDA L V, SWIECH M, DELGADO M, et al. PID control of MIMO process based on rank niching genetic algorithm [J]. Applied Intelligence, 2008, 29(3): 290-305.
- [23] 薄永军. 温室温度控制系统神经网络 PID 控制算法研究 [J]. 安徽农业科学, 2014, 42(13): 4102-4.
- [24] LIANG H, LIU G, ZHANG H, et al. Neural-network-based event-triggered adaptive control of nonaffine nonlinear multiagent systems with dynamic uncertainties [J]. IEEE Transactions on Neural Networks and Learning Systems, 2020, 32(5): 2239-50.
- [25] SHEN Q, SHI P, ZHU J, et al. Neural networks-based distributed adaptive control of nonlinear multiagent systems [J]. IEEE Transactions on Neural Networks and Learning Systems, 2019, 31(3): 1010-21.
- [26] 李二. 基于改进 PSO 算法的 PID 参整定及在造纸定量控制中的应用 [D]; 上海交通大学, 2019.
- [27] MOHAMMADI B, RANJBAR S F, AJABSHIRCHI Y. Application of dynamic model to predict some inside environment variables in a semi-solar greenhouse [J]. Information processing in agriculture, 2018, 5(2): 279-88.
- [28] TAKI M, MEHDIZADEH S A, ROHANI A, et al. Applied machine learning in greenhouse simulation; new application and analysis [J]. Information processing in agriculture, 2018, 5(2): 253-68.
- [29] MARLIN T E. Process control [J]. Chemical Engineering Series, McGraw-Hill International Editions: New York, 1995.
- [30] LIU T, WANG Q-G, HUANG H-P. A tutorial review on process identification from step or relay feedback test [J]. Journal of Process control, 2013, 23(10): 1597-623.
- [31] BURN K, COX C. A hands-on approach to teaching system identification using first-order plus dead time modelling of step response data [J]. The International Journal of Electrical Engineering & Education, 2020, 57(1): 24-40.
- [32] 穆叶, 胡天立, 陈晨, et al. 采用模拟 PID 控制的 DFB 激光器温度控制系统研制 [J]. 红外与激光工程, 2019, 48(4): 405001-0405001 (7).

- [33] 叶雯雯, 管光华, 李一鸣, et al. 串联输水明渠 PID 多指标自适应算法及仿真研究 [J]. 中国农村水利水电, 2019, 1: 120-6.
- [34] 李辉, 史荣珍. PID 控制器参数整定与分析 [J]. 电脑知识与技术, 2019, 15(8): 243-4.
- [35] MOKEDDEM D, MIRJALILI S. Improved Whale Optimization Algorithm applied to design PID plus second-order derivative controller for automatic voltage regulator system [J]. Journal of the Chinese Institute of Engineers, 2020, 43(6): 541-52.
- [36] 廖丹, 高宏力, 邱德军, et al. 球形机器人非线性 PID 控制器研究与设计 [J]. 机械设计与制造, 2020, 3.
- [37] 邹志云, 朱文超, 刘英莉, et al. 小型特种精细化工过程自动化和信息化研究发展趋势探讨 [J]. 化工进展, 2020, 39(S2): 269-75.
- [38] PATTNAIK A, ROUT B, PATRA A K. Comparative Study of System Performances Using Integral Type LQR with DE and ZN Optimized PID [J]. Advances in Electrical Control and Signal Systems: Select Proceedings of AECSS 2019, 2020, 665: 349.
- [39] 王贵荣. 智能算法在水轮机调速器 PID 参数优化中的应用 [D]; 昆明理工大学, 2020.
- [40] HOLLAND J H, REITMAN J S. Cognitive systems based on adaptive algorithms [M]. Pattern-directed inference systems. Elsevier. 1978: 313-29.
- [41] DE JONG K A. An analysis of the behavior of a class of genetic adaptive systems [M]. University of Michigan, 1975.
- [42] KATOCH S, CHAUHAN S S, KUMAR V. A review on genetic algorithm: past, present, and future [J]. Multimedia Tools and Applications, 2021, 80(5): 8091-126.
- [43] 赵志浩. 基于遗传算法的印版滚筒 PID 温控箱研究与设计 [D]; 成都理工大学, 2018.
- [44] 王贵荣. 智能算法在水轮机调速器 PID 参数优化中的应用 [D]; 昆明理工大学, 2020.
- [45] 汪培萍. 一种改进的自适应遗传算法及在智能排课系统中的应用研究 [D]; 广东技术师范大学, 2020.
- [46] 肖夏. 基于改进遗传算法的云计算任务调度算法的研究和实现 [D]; 重庆邮电大学, 2019.
- [47] 邹贵祥, 张飞舟. 针对选址问题的一种遗传算法改进探究 [J]. 计算机工程与科学, 2018, 40(4): 712-22.
- [48] 张静, 高尚. 基于轮盘赌反向选择机制的果蝇优化算法 [J]. 计算机与数字工程, 2020, 48(07): 1595-600+742.
- [49] 梁芳. 遗传算法的改进及其应用 [D]; 武汉理工大学, 2008.
- [50] 晏亭太. 智能自适应 PID/PD 控制器设计及仿真研究 [D]; 哈尔滨: 哈尔滨工业大学, 2014.
- [51] 于洋, 徐晓, 朱常志, et al. 冀中地区日光温室空间温度场分布规律实验研究 [J]. 河北农业大学学报, 2019, 42(05): 124-9.
- [52] 皇甫立群. 基于改进 B 样条神经网络-PID 控制器的温室温度控制技术 [J]. 中国农机化学报,

2020, 41(07): 68-74.

- [53] 陆万荣, 许江淳, 曾德斌, et al. 基于增量式 PID 算法的温室温湿度控制系统设计 [J]. 中国农机化学报, 2018, 39(04): 72-6.
- [54] 黄金侠, 侯艳, 宋国义, et al. PID 神经网络在水稻秧棚控制系统中的应用研究 [J]. 农机化研究, 2019, 7.
- [55] DA SILVA L E B, ELNABARAWY I, WUNSCH II D C. A survey of adaptive resonance theory neural network models for engineering applications [J]. Neural Networks, 2019, 120: 167-203.
- [56] 刘宪民. 神经网络在汽轮机控制系统上的研究 [J]. 科技资讯, 2020.
- [57] 罗莉. 忆阻神经网络同步控制的研究 [D]; 南京理工大学, 2019.
- [58] ARABASADI Z, ALIZADEHSANI R, ROSHANZAMIR M, et al. Computer aided decision making for heart disease detection using hybrid neural network-Genetic algorithm [J]. Computer methods and programs in biomedicine, 2017, 141: 19-26.
- [59] 陈晓东. 基于 OneNET 云平台的花棚温控系统研究与实现 [D]; 辽宁大学, 2020.
- [60] 程仕发. 智能温室大棚监控系统的设计 [D]; 太原理工大学, 2020.
- [61] 吴晨红. 基于 Modbus 通信协议的信号采集系统 [D]; 合肥工业大学, 2021.
- [62] 刘媛. 基于 CAN 现场总线的激光器远程监控系统 [D]; 华中科技大学, 2019.
- [63] 徐晓霞. 基于 STM32 的电压采集系统设计 [J]. 电子设计工程, 2019, 27(17): 76-9.

作者简介

一、个人基本情况

何雨宏，男，汉族，共青团员，1998 年 3 月出生，籍贯为安徽省安庆市

二、教育及工作经历

2016.09—2020.06 皖西学院计算机科学与技术专业，工学学士

2020.09—2022.06 安徽农业大学农业工程与信息技术专业，农学硕士

三、获得奖励

2020—2021 学年，获得专业三等奖学金